本资源来自编程导航：https://codefather.cn

推荐更多免费学编程资源：

1. *编程导航学习网站：学编程、做项目、拿 Offer！*
2. *企业高频面试题库：开始刷题，面试遇原题！*
3. *精选简历模板大全：1 分钟搞定简历！*
4. *AI 资源导航网站：获取最新 AI 黑科技！*
5. *1 对 1 模拟面试：随时随地提升面试能力*

AI 大模型应用开发学习路线 | 25 年最新零基础到精通一条龙（万人收藏⭐）

AI 大模型高频面试题：开始刷题 Spring AI 教程专栏：加入学习 Langchain 教程专栏：加入学习

介绍

最近几年，AI 大模型已成为科技领域最热门的话题之一。从ChatGPT的爆火到国内 Deepseek、通义千问等产品的涌现，大模型正在刷新我们对人工智能的认知。那么，究竟什么是AI大模型？它为何能在短时间内引发如此巨大的关注？作为后端开发人员，我们又该如何利用这一技术构建创新应用？

简单来说，AI大模型是指通过海量数据和强大算力训练出的超大规模神经网络。这类模型通常包含数十亿甚至数万亿个参数，能够处理和理解复杂的信息模式。以OpenAI的GPT-4为例，其参数量高达1.8万亿，训练数据规模相当于数百万本书的内容。这种复杂的模型结构，具有非常强大的能力，比如说理解上下文、生成连贯文本，甚至跨模态处理图像与语言。大模型的核心优势在于其预训练+微调的范式。预训练阶段，模型通过无监督学习从互联网规模的通用数据中吸收知识；微调阶段则针对特定任务进行优化。这种模式打破了传统AI"一个任务一个模型"的局限，让单一模型能够灵活适应多种场景。

与传统AI开发不同，大模型应用开发的核心不是从头训练模型，而是通过工程化手段释放现成模型的潜力。这就像组装乐高积木——开发者需要巧妙组合Prompt工程、向量数据库、业务逻辑等模块，将通用大模型训练为特定场景的解决方案。

以个人知识库助手为例，开发者只需将用户文档转化为向量嵌入，再通过语义检索找到相关片段作为上下文，就能让GPT-4等模型生成精准回答。

学习建议

如果你是个后端开发者如何转向 AI 大模型应用开发呢？

想要从传统的业务开发转向 AI 应用开发。但是，大部分人对这个转型的具体路径还是比较迷茫的：要不要去学 PyTorch？是不是得先补一补机器学习和数学？后端开发的经验能不能在 AI 领域复用？

其实，从后端转 AI 应用开发，不是简单的 “换个技术栈” ，而是思维方式、工程经验、业务理解能力的综合迁移。

AI 应用的核心逻辑

很多人一提到 AI，就觉得是“高深的数学 + 复杂的算法 + 神秘的模型”。但如果你的目标是做 AI 应用，而不是去研究新模型，那么核心思路其实跟做后端业务没什么本质区别的：

1）大模型本质上是个 **强大的 API**，它能做的事情远比普通 API 复杂，但它仍然需要业务逻辑去组织。

2） 你需要设计 **Prompt**（提示词工程），就像写 SQL 查询一样，要学会用“对 AI 友好的方式” 让它输出符合需求的内容。

3） 你需要**处理上下文**、存储用户数据、结合业务规则，而这些其实是后端开发最擅长的部分。

换句话说，AI 应用开发的关键，不是研究 AI 本身，而是学会 **如何围绕 AI 设计出好用的产品**。

后端开发的优势

很多人觉得 AI 相关的工作应该由算法工程师或者机器学习专家来做，但实际上，后端开发者在 AI 应用落地上有天然的优势。

首先，后端开发者对 **系统架构、数据处理、性能优化** 都有深入的理解，而 AI 应用的落地往往需要这些能力。比如，你要做一个 AI 面试官，它需要：

- 通过 `WebSocket` 或者 `SSE` 来进行流式实时通信。
- 使用 `MySQL` 来存储用户的历史对话，避免每次请求都从零开始。
- 使用 `TTS` 来实现进行实时语音对话功能

这些需求，本质上和普通的后端开发没什么区别，只是服务的核心逻辑变成了 “调用大模型” 而已。

其次，后端开发者更熟悉 **业务需求和应用工程化落地**。大多数AI 算法专家更擅长优化模型，而不是做一个真正好用的产品。能把大模型接入业务场景，并且优化体验、降低成本，这种能力是非常稀缺的。

学习目标

当然，后端开发者转 AI 还是有一些新的东西需要学习，但比想象中简单得多。

- **理解大模型的能力边界**：很多人对 AI 的能力有误解，觉得它能解决所有问题，但实际上，大模型有明显的上下文限制、幻觉问题、稳定性问题。你需要了解它的优势和局限，才能用好它。
- **掌握 Prompt 设计**：不同的提示词会影响大模型的输出，甚至决定最终产品的效果。比如 “你是谁？” 和 “你是一个 Java 面试官，请问 Spring Boot 的核心特性是什么？” 这两种问法，得到的答案完全不同。
- **熟悉 LangChain、RAG、LLM、向量数据库**：这些工具能帮助你更高效地搭建 AI 应用，比如用向量数据库（如 Milvus、Faiss）做长文本搜索，用 LangChain 处理复杂的多轮对话。

但整体来看，后端开发者完全可以 **沿着自己的经验积累** 来进入 AI 领域，而不需要完全推翻已有的知识体系。

学习路线

可以按照这个路线去学习：

1）大模型基础

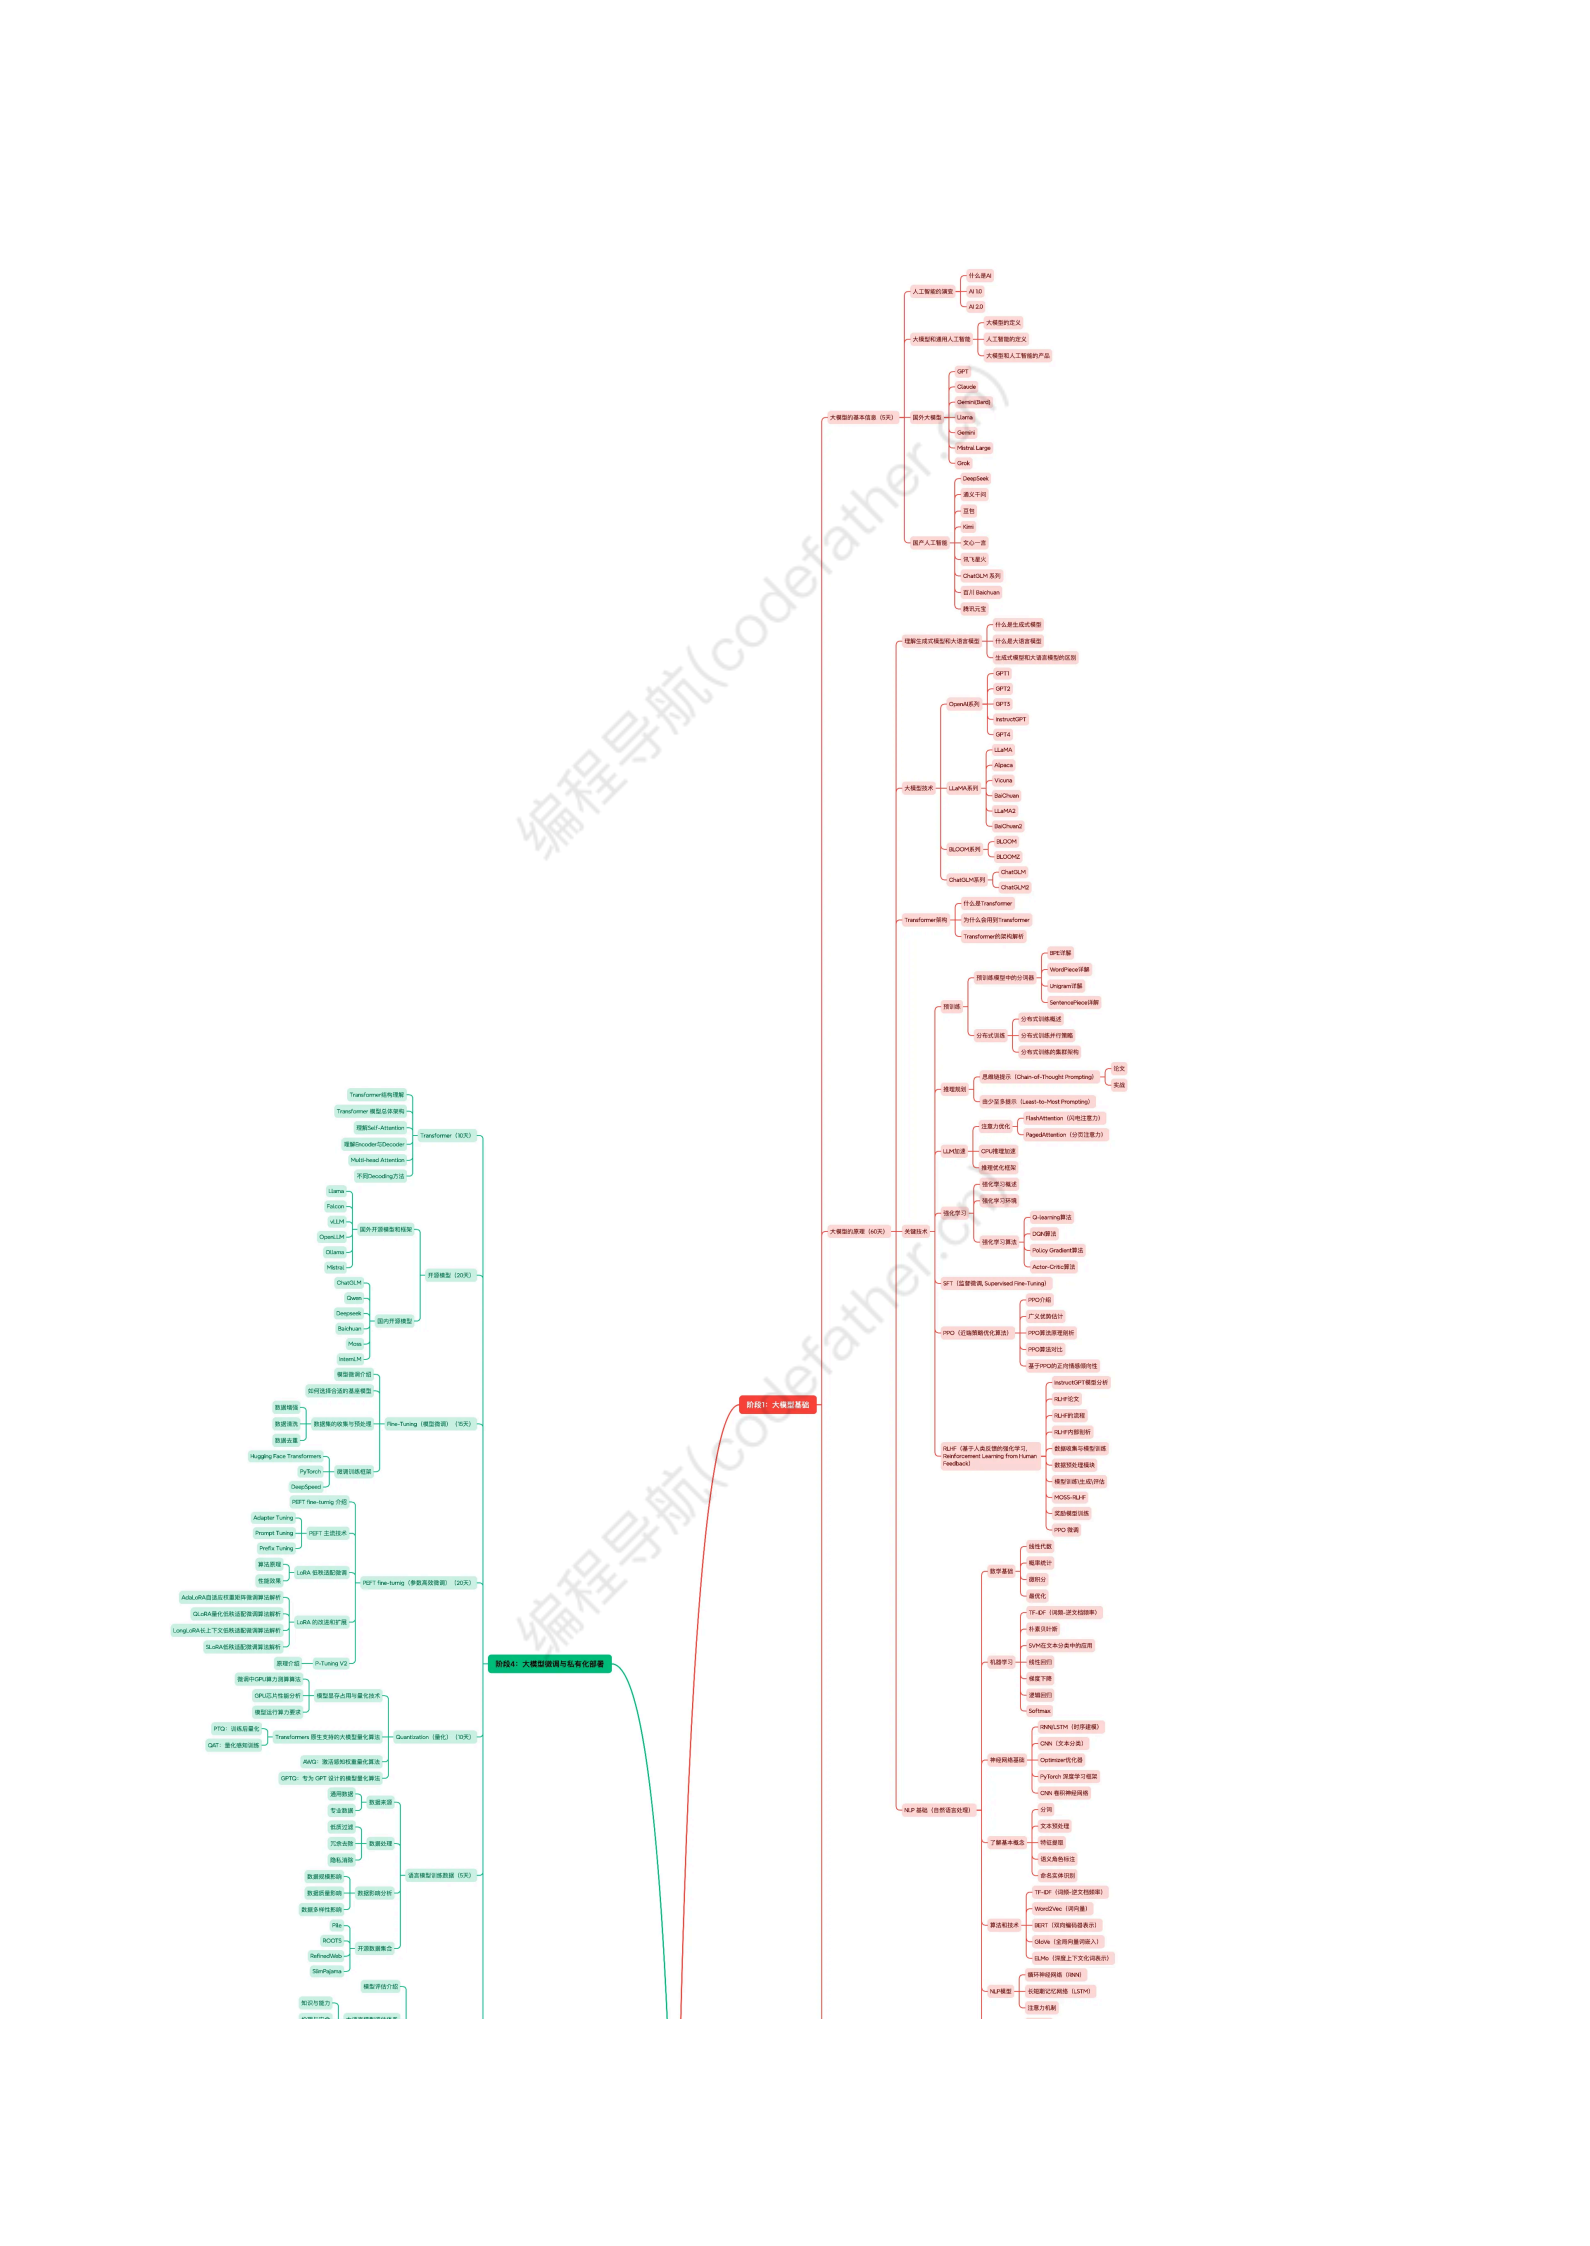
2）AI大模型与RAG应用开发工程

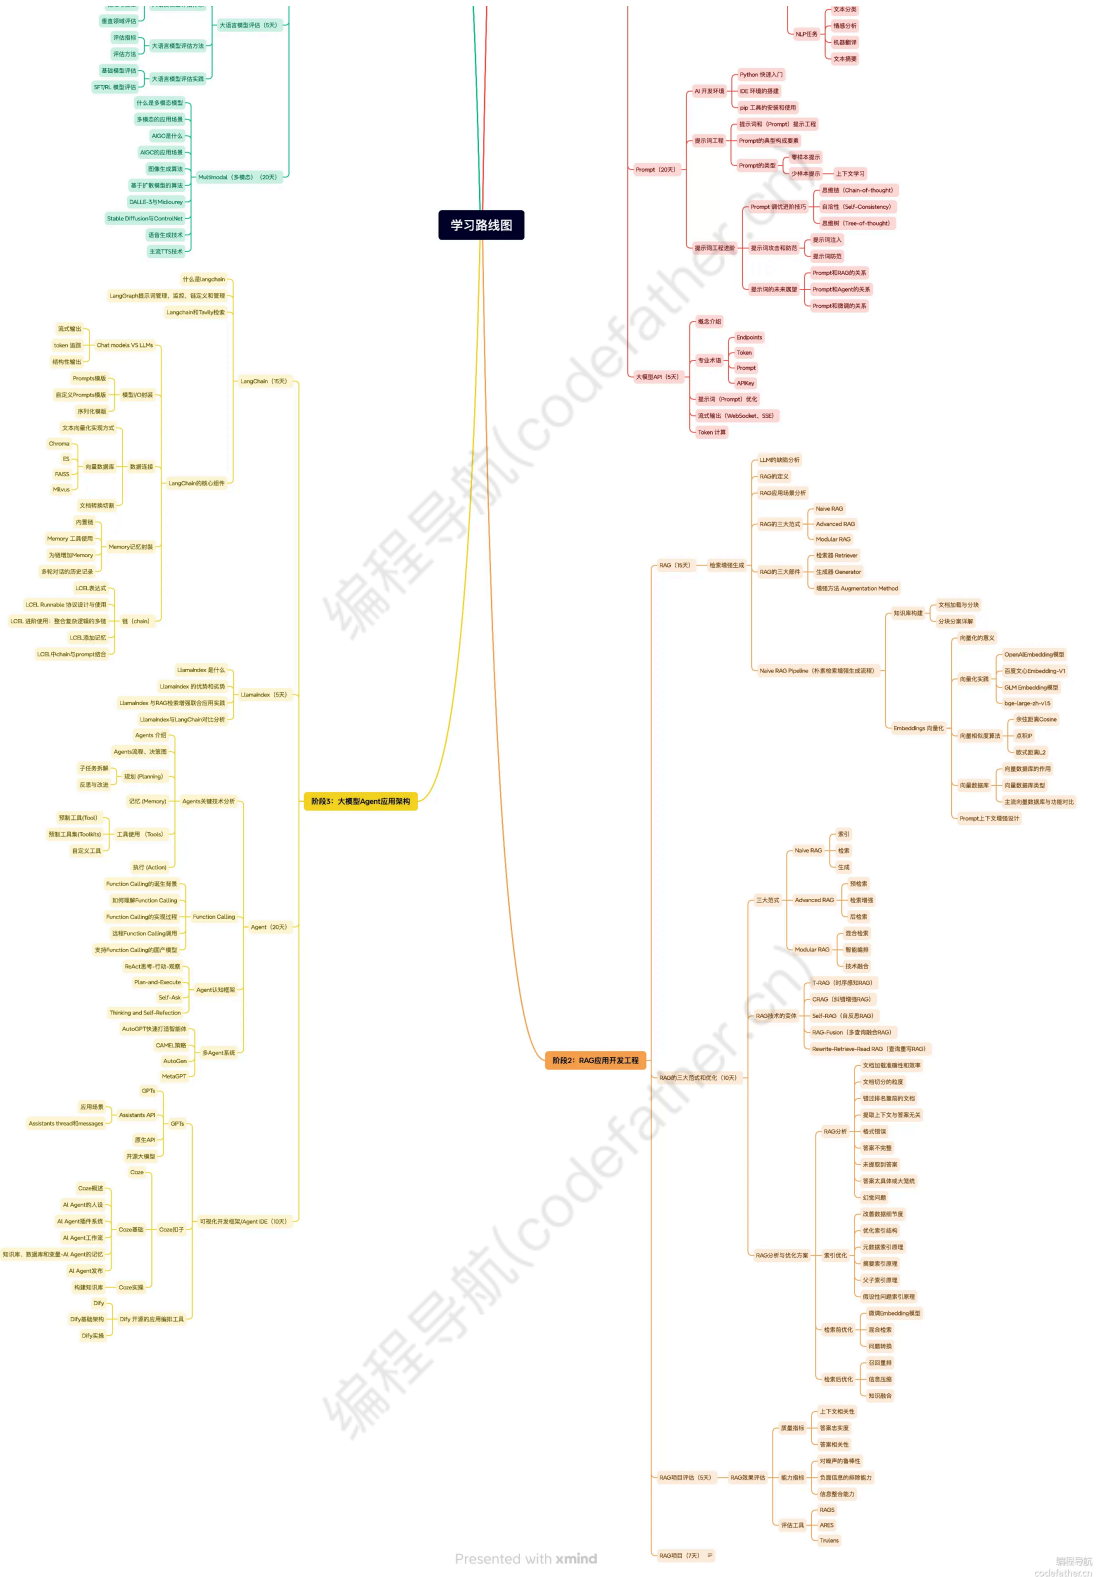
3）大模型Agent应用架构

4）大模型微调与私有化部署

路线图：

编程导航(codefather.cn)


阶段1：大模型基础
大模型的基本信息（5天）
人工智能的演变
什么是AI
AI 1.0
AI 2.0
大模型和通用人工智能
大模型的定义
人工智能的定义
大模型和人工智能的产品
国外大模型
GPT
Claude
Gemini(Bard)
Llama
Gemini
Mistral Large
Grok
国产人工智能
DeepSeek
通义千问
豆包
Kimi
文心一言
讯飞星火
ChatGLM 系列
百川 Baichuan
腾讯元宝
大模型的原理（60天）
理解生成式模型和大语言模型
什么是生成式模型
什么是大语言模型
生成式模型和大语言模型的区别
大模型技术
OpenAI系列
GPT1
GPT2
GPT3
InstructGPT
GPT4
LLaMA系列
LLaMA
Alpaca
Vicuna
BaiChuan
LLaMA2
BaiChuan2
BLOOM系列
BLOOM
BLOOM2
ChatGLM系列
ChatGLM
ChatGLM2
Transformer架构
什么是Transformer
为什么会用到Transformer
Transformer的架构解析
关键技术
预训练
预训练模型中的分词器
BPE详解
WordPiece详解
Unigram详解
SentencePiece详解
分布式训练
分布式训练概述
分布式训练并行策略
分布式训练的集群架构
推理规划
思维链提示（Chain-of-Thought Prompting）
论文
实战
由少至多提示（Least-to-Most Prompting）
LLM加速
注意力优化
FlashAttention（闪电注意力）
PagedAttention（分页注意力）
CPU推理加速
推理优化框架
强化学习
强化学习概述
强化学习环境
强化学习算法
Q-learning算法
DQN算法
Policy Gradient算法
Actor-Critic算法
SFT（监督微调 Supervised Fine-Tuning）
PPO（近端策略优化算法）
PPO介绍
广义优势估计
PPO算法原理剖析
PPO算法对比
基于PPO的正向情感倾向性
RLHF（基于人类反馈的强化学习，Reinforcement Learning from Human Feedback）
InstructGPT模型分析
RLHF论文
RLHF的流程
RLHF内部剖析
数据收集与模型训练
数据预处理模块
模型训练(生成)评估
MOSS-RLHF
奖励模型训练
PPO 微调
NLP 基础（自然语言处理）
数学基础
线性代数
概率统计
微积分
最优化
机器学习
TF-IDF（词频-逆文档频率）
朴素贝叶斯
SVM在文本分类中的应用
线性回归
梯度下降
逻辑回归
Softmax
神经网络基础
RNN(LSTM（时序建模）
CNN（文本分类）
Optimizer优化器
PyTorch 深度学习框架
CNN 卷积神经网络
了解基本概念
分词
文本预处理
特征提取
语义角色标注
命名实体识别
算法和技术
TF-IDF（词频-逆文档频率）
Word2Vec（词向量）
BERT（双向编码器表示）
Glove（全局向量词嵌入）
ELMo（深度上下文化词表示）
NLP模型
循环神经网络（RNN）
长短期记忆网络（LSTM）
注意力机制
阶段4：大模型微调与私有化部署
Transformer（10天）
Transformer结构理解
Transformer 模型总体架构
理解Self-Attention
理解Encoder与Decoder
Multi-head Attention
不同Decoding方法
开源模型（20天）
国外开源模型和框架
Llama
Falcon
vLLM
OpenLLM
DLlama
Mistral
国内开源模型
ChatGLM
Qwen
Deepseek
Baichuan
Moss
InternLM
Fine-Tuning（模型微调）（15天）
模型微调介绍
如何选择合适的基座模型
数据集的收集与预处理
数据增强
数据清洗
数据去重
微调训练框架
Huggling Face Transformers
PyTorch
DeepSpeed
PEFT fine-tuning（参数高效微调）（20天）
PEFT fine-tuning 介绍
PEFT 主流技术
Adapter Tuning
Prompt Tuning
Prefix Tuning
LoRA 低秩适配微调
算法原理
性能效果
LoRA 的改进和扩展
AdaLoRA自适应权重矩阵微调算法解析
QLoRA量化低秩适配微调算法解析
LongLoRA长上下文低秩适配微调算法解析
SLoRA低秩适配微调算法解析
P-Tuning V2
原理介绍
Quantization（量化）（10天）
做需中GPU算力资源算法
模型显存占用与量化技术
GPU芯片性能分析
模型运行算力要求
Transformers 原生支持的大模型量化算法
PTQ：训练后量化
QAT：量化感知训练
AWQ：激活感知权重量化算法
GPTQ：专为 GPT 设计的模型量化算法
语言模型训练数据（5天）
数据来源
通用数据
专业数据
数据处理
低质过滤
冗余去除
隐私消除
数据对比分析
数据规模影响
数据质量影响
数据多样性影响
开源数据集合
Pile
ROOTS
RefinedWeb
SlimPajama
模型评估介绍
知识与能力



阶段1：大模型基础

大模型的基本信息（5天）

知识

编程导航(codefather.cn)

编程导航(codefather.cn)

- 人工智能的演变
  - 什么是AI
  - AI 1.0
  - AI 2.0
- 大模型和通用人工智能
  - 大模型的定义
  - 人工智能的定义
  - 大模型和人工智能的产品

- 国外大模型
  - GPT
  - Claude
  - Gemini(Bard)
  - Llama
  - Gemini
  - Mistral Large
  - Grok
- 国产人工智能
  - DeepSeek
  - 通义千问
  - 豆包
  - Kimi
  - 文心一言
  - 讯飞星火
  - ChatGLM 系列
  - 百川 Baichuan
  - 腾讯元宝

学习建议

- **打基础**：可以先从一些入门书籍、视频课程开始，比如 B站上关于 AI 历史和大模型技术的课程，了解概念和背景。
- **关注动态**：多关注一些技术博客和论坛，比如huggingface、GitHub上的开源模型和项目，及时了解国外和国内的最新进展。
- **动手实践**：可以从简单的例子入手，比如使用ChatGPT或者DeepSeek进行对话，看看是怎么输出的。

学习资源

1）李沐讲AI（动手学深度学习在线课程）

课程：https://courses.d2l.ai/zh-v2/

视频：https://space.bilibili.com/1567748478?

2）马士兵-AI大模型全套教程

https://www.bilibili.com/video/BV128cUe6EU2/

3）AI大模型零基础全套教程

https://www.bilibili.com/video/BV1uNk1YxEJQ

经典面试题（更多面试题）

1）人工智能的发展经历了哪些主要阶段？请简要概述每个阶段的特点。

2）如何理解大模型与通用人工智能（AGI）之间的关系？它们在目标和实现上有何区别？

3）请列举当前国际上主流的大型语言模型，并简要介绍它们的特点和应用场景。

4）在国产人工智能领域，您了解哪些具有代表性的大模型？它们在技术和应用上有哪些突破？

5）Transformer架构在大模型中扮演什么角色？其核心机制是什么？

大模型的原理（60天）

知识

编程导航(codefather.cn)

- 理解生成式模型和大语言模型
  - 什么是生成式模型
  - 什么是大语言模型
  - 生成式模型和大语言模型的区别
- 大模型技术
  - OpenAI系列
    - GPT1
    - GPT2
    - GPT3
    - InstructGPT
    - GPT4
  - LLaMA系列
    - LLaMA
    - Alpaca
    - Vicuna
    - BaiChuan
    - LLaMA2
    - BaiChuan2
  - BLOOM系列
    - BLOOM
    - BLOOMZ
  - ChatGLM系列
    - ChatGLM
    - ChatGLM2
- Transformer架构
  - 什么是Transformer
  - 为什么会用到Transformer
  - Transformer的架构解析
- NLP基础（自然语言处理）
  - 数学基础
    - 线性代数
    - 概率统计
    - 微积分
    - 最优化
  - 机器学习
    - TF-IDF（词频-逆文档频率）
    - 朴素贝叶斯
    - SVM在文本分类中的应用
    - 线性回归
    - 梯度下降
    - 逻辑回归
    - Softmax
  - 神经网络基础
    - RNN/LSTM（时序建模）
    - CNN（文本分类）

编程导航(codefather.cn)
编程导航(codefather.cn)

        - Optimizer优化器
        - PyTorch 深度学习框架
        - CNN 卷积神经网络
    - 了解基本概念
        - 分词
        - 文本预处理
        - 特征提取
        - 语义角色标注
        - 命名实体识别
    - 算法和技术
        - TF-IDF（词频-逆文档频率）
        - Word2Vec（词向量）
        - BERT（双向编码器表示）
        - GloVe（全局向量词嵌入）
        - ELMo（深度上下文化词表示）
    - NLP模型
        - 循环神经网络（RNN）
        - 长短期记忆网络（LSTM）
        - 注意力机制
    - NLP任务
        - 文本分类
        - 情感分析
        - 机器翻译
        - 文本摘要

- 关键技术
    - 预训练
        - 预训练模型中的分词器
            - BPE详解
            - WordPiece详解
            - Unigram详解
            - SentencePiece详解
        - 分布式训练
            - 分布式训练概述
            - 分布式训练并行策略
            - 分布式训练的集群架构
    - 推理规划
        - 思维链提示（Chain-of-Thought Prompting）
            - 论文
            - 实战
        - 由少至多提示（Least-to-Most Prompting）
    - LLM加速
        - 注意力优化
            - FlashAttention（闪电注意力）
            - PagedAttention（分页注意力）
        - CPU推理加速
        - 推理优化框架

编程导航(codefather.cn)
编程导航(codefather.cn)

- 强化学习
  - 强化学习概述
  - 强化学习环境
  - 强化学习算法
    - Q-learning算法
    - DQN算法
    - Policy Gradient算法
    - Actor-Critic算法
- SFT（监督微调, Supervised Fine-Tuning）
- PPO（近端策略优化算法）
  - PPO介绍
  - 广义优势估计
  - PPO算法原理剖析
  - PPO算法对比
  - 基于PPO的正向情感倾向性
- RLHF（基于人类反馈的强化学习, Reinforcement Learning from Human Feedback）
  - InstructGPT模型分析
  - RLHF论文
  - RLHF的流程
  - RLHF内部剖析
  - 数据收集与模型训练
  - 数据预处理模块
  - 模型训练\生成\评估
  - MOSS-RLHF
  - 奖励模型训练
  - PPO 微调

学习建议

- **夯实基础：** 无论学习什么，基础是最重要的，可以从自然语言处理（NLP）的基础知识开始，包括数学基础、机器学习和神经网络等概念。理解这些基础知识将有助于你更好地掌握后面的内容，也能在后面解决问题时节省很多时间。但是也不要死磕基础知识的原理，不用去卷数学证明或底层推导，只需要掌握理解模型结构所需的知识点，知道最里面的算法和流程，能看懂主流模型是怎么工作的，怎么训练和使用的，除非你想造模型，大模型的应用开发更重工程能力。
- **理解核心概念：** 深入学习生成式模型、大语言模型以及Transformer架构，掌握预训练、推理规划、强化学习等关键技术。
- **关注实践：** 理论结合实践，尝试在本地部署小型模型，完成简单的文本生成任务，以加深对理论的理解。

学习资源

1）NLP 新手入门教程

https://github.com/PKU-TANGENT/nlp-tutorial

2）Transformers 教程

https://transformers.run/

3）深入理解Transformer技术原理

https://tech.dewu.com/article?id=109

4）Transformer 是如何工作的

https://huggingface.co/learn/llm-course/zh-CN/chapter1/4

编程导航(codefather.cn)

5）HuggingFace快速入门

https://huggingface.co/docs/transformers/quicktour

6）动手学大模型应用开发

https://datawhalechina.github.io/llm-universe/#/

7）基于transformers的自然语言处理(NLP)入门

https://datawhalechina.github.io/learn-nlp-with-transformers/#/

8）Ollama本地模型部署

https://ollama.ai/

9）LLM/AI 大模型入门指南

https://zhuanlan.zhihu.com/p/722000336

经典面试题（更多面试题）

1）说说你了解的机器学习是什么？

2）监督学习、半监督学习和无监督学习分别是什么，它们的区别在哪？

3）什么是词嵌入（Word Embedding）？有哪些常见的词嵌入方法？

4）什么是深度学习？它与传统机器学习有什么区别？

5）如何评估一个深度学习模型的性能？

Prompt（20天）

知识

- AI 开发环境
    - Python 快速入门
    - IDE 环境的搭建
    - pip 工具的安装和使用
- 提示词工程
    - 提示词和（Prompt）提示工程
    - Prompt的典型构成要素
    - Prompt的类型
        - 零样本提示
        - 少样本提示
            - 上下文学习
- 提示词工程进阶
    - Prompt 调优进阶技巧
        - 思维链（Chain-of-thought）
        - 自洽性（Self-Consistency）
        - 思维树（Tree-of-thought）
    - 提示词攻击和防范
        - 提示词注入

编程导航(codefather.cn)

        - 提示词防范
    - 提示词的未来展望
        - Prompt和RAG的关系
        - Prompt和Agent的关系
        - Prompt和微调的关系

学习建议

学习AI 免不了要跟Python打交道，因为AI的很多库和框架都是Python写的，所以我们首先要学好Python，在编程导航也有Python的学习路线，可以看下下面的学习资源的链接。

对于提示词工程，这部分其实是大模型应用中一个很有意思的环节。你需要先搞清楚什么叫Prompt，了解它的概念、作用，以及如何通过设计有效的提示词来引导大模型生成期望的输出。然后来再一步步试着调试和优化Prompt的效果，这个过程很大程度上依赖于不断地实践和尝试，所以一定要动手尝试，才能将所学知识应用于实际问题，强化理解。

学习资源

1）Python学习路线

https://www.codefather.cn/course/1789189862986850306/section/1789190283176419330?type=#

2）OpenAI官方Prompt工程指南

https://platform.openai.com/docs/guides/prompt-engineering

3）Prompt模板库

https://github.com/f/awesome-chatgpt-prompts

4）提示词工程指南

https://www.promptingguide.ai/zh

https://github.com/dair-ai/Prompt-Engineering-Guide

经典面试题（更多面试题）

1）什么样的 prompt 是好的 prompt?

2） 你给 AI 预设的 Prompt 结构是什么样的？如何优化 Prompt

3）什么是提示词攻击？有哪些常见的防范措施可以提高模型的安全性？

4）请解释提示词的不同类型，并讨论它们在实际应用中的适用场景。

大模型API（3天）

知识

- 概念介绍
- 专业术语
    - Endpoints
    - Token
    - Prompt
    - APIKey
- 提示词（Prompt）优化

编程导航(codefather.cn)

- 流式输出（WebSocket、SSE）
- Token 计算

学习建议

调大模型API其实跟调用普通的接口是一样的，了解其中的输入输出参数，调用方法，不同的是，如果想要实时的输出，需要通过SSE或者WebSocket的方式来模拟打字机的效果。另外，你需要知道的是，大模型API里有一个比较重要的概念，那就是token，需要知道它是怎么计算的，因为它是跟钱相关的，涉及到费用计算。然后就是多去实践，现在很多网站注册都会送很多的token，可以去调用试一下效果。

学习资源

1）OpenAI的API文档

https://platform.openai.com/docs/api-reference/introduction

2）OpenAI 的token计算器

https://platform.openai.com/tokenizer

3）Deepseek的API文档

https://api-docs.deepseek.com/

经典面试题（更多面试题）

1）什么是Token？在大模型API中，如何计算输入和输出的Token数量？

2）流式输出在大模型API中有哪些实现方式？请比较WebSocket和SSE的特点及适用场景。

3）在使用大模型API时，如何确保API密钥的安全性？请说明常用的安全措施。

阶段2：RAG应用开发工程

RAG（15天）

知识

- 检索增强生成
  - LLM的缺陷分析
  - RAG的定义
  - RAG应用场景分析
  - RAG的三大范式
    - Naive RAG
    - Advanced RAG
    - Modular RAG
  - RAG的三大部件
    - 检索器 Retriever
    - 生成器 Generator
    - 增强方法 Augmentation Method
  - Naive RAG Pipeline（朴素检索增强生成流程）
    - 知识库构建
      - 文档加载与分块

编程导航(codefather.cn)

        - 分块方案详解
    - Embeddings 向量化
        - 向量化的意义
        - 向量化实践
            - OpenAIEmbedding模型
            - 百度文心Embedding-V1
            - GLM Embedding模型
            - bge-large-zh-v1.5
        - 向量相似度算法
            - 余弦距离Cosine
            - 点积IP
            - 欧式距离L2
        - 向量数据库
            - 向量数据库的作用
            - 向量数据库类型
            - 主流向量数据库与功能对比
    - Prompt上下文增强设计

学习建议

RAG现在挺火的，它本质上就是让大模型先查资料再回答问题，比直接训练模型要容易上手。你可以从了解它的基本概念开始，先思考一下为什么需要检索增强，不理解其中的技术细节也没关系，可以先从一个项目例子入手，比如让系统先从某个文档集合中找到相关内容，再将这些内容作为输入传递给生成模型，看看它能如何生成更准确的答案。在实践的过程中可以看看它是怎么运行的，了解下RAG的流程。然后可以着重理解RAG的应用场景和它在实际项目中的工作原理，再逐步深入学习如何调优检索部分和生成部分的协同工作，如何评估结果，并做性能优化，并且可以了解下里面用到的技术。

学习资源

1）Hugging Face的RAG文档，详细介绍了如何实现和应用RAG

https://huggingface.co/docs/transformers/main/en/model_doc/rag

2）基于 RAG 的知识库管理

https://github.com/rag-web-ui/rag-web-ui

3）RAG教程

https://www.bilibili.com/video/BV1hccSeJEUD

4）用 Hugging Face Zephyr 和 LangChain 针对 Github issues 构建简单的 RAG

https://huggingface.co/learn/cookbook/zh-CN/rag_zephyr_langchain

5）手把手带你结合企业级项目实战完成一套完整的RAG项目

https://www.bilibili.com/video/BV1YaRhY9EqV

经典面试题（更多面试题）

1）什么是 RAG？RAG 的主要流程是什么？

2）什么是 RAG 中的 Rerank？具体需要怎么做？

3）当发现RAG系统召回结果与用户query意图不匹配时，有哪些可能的改进方向？

编程导航(codefather.cn)

4）如何评测大模型的幻觉？

RAG的三大范式和优化（10天）

知识

- 三大范式
  - Naive RAG
    - 索引
    - 检索
    - 生成
  - Advanced RAG
    - 预检索
    - 检索增强
    - 后检索
  - Modular RAG
    - 混合检索
    - 智能编排
    - 技术融合
- RAG技术的变体
  - T-RAG（时序感知RAG）
  - CRAG（纠错增强RAG）
  - Self-RAG（自反思RAG）
  - RAG-Fusion（多查询融合RAG）
  - Rewrite-Retrieve-Read RAG（查询重写RAG）
- RAG分析与优化方案
  - RAG分析
    - 文档加载准确性和效率
    - 文档切分的粒度
    - 错过排名靠前的文档
    - 提取上下文与答案无关
    - 格式错误
    - 答案不完整
    - 未提取到答案
    - 答案太具体或太笼统
    - 幻觉问题
  - 索引优化
    - 改善数据细节度
    - 优化索引结构
    - 元数据索引原理
    - 摘要索引原理
    - 父子索引原理
    - 假设性问题索引原理
  - 检索前优化
    - 微调Embedding模型
    - 混合检索
    - 问题转换
  - 检索后优化

编程导航(codefather.cn)
编程导航(codefather.cn)

        - 召回重排
        - 信息压缩
        - 知识融合

学习建议

这一阶段主要是深入学习RAG的一些优化技术和设计，如三大范式等。可以重点关注 RAG 的核心机制，如检索、生成、索引优化、检索前后优化等。深入理解这些概念，有助于在实际应用中灵活运用。可以多看一些网上的文章，这样有助于理解。

学习资源

1）一文读懂：大模型RAG（检索增强生成）含高级方法

https://zhuanlan.zhihu.com/p/675509396

2）RAG 技术的发展历程

https://developer.aliyun.com/article/1597639

3）RAG 优化方案与实践

https://zhuanlan.zhihu.com/p/703182970

4）RAG 范式、技术和趋势

https://www.cnblogs.com/xiaoqi/p/18075992/rag-survey

经典面试题（更多面试题）

1）请比较Naive RAG、Advanced RAG和Modular RAG三种范式的主要区别，以及它们各自适用的应用场景。

2）在RAG技术的变体中，T-RAG、CRAG和Self-RAG分别解决了哪些特定问题？

3）在RAG系统的索引优化过程中，如何利用元数据索引、摘要索引和父子索引来提升检索效率？

4）针对RAG系统中常见的幻觉问题，您会采用哪些分析与优化方案来减少其发生？

5）在检索前优化阶段，微调Embedding模型和混合检索各有哪些优势？

RAG项目评估（5天）

知识

- RAG效果评估
    - 质量指标
        - 上下文相关性
        - 答案忠实度
        - 答案相关性
    - 能力指标
        - 对噪声的鲁棒性
        - 负面信息的排除能力
        - 信息整合能力
    - 评估工具
        - RAGAS
        - ARES
        - Trulens

学习建议

编程导航(codefather.cn)

如何评估RAG项目的效果是确保模型性能和提升用户体验的关键一步。在这一阶段，你需要掌握质量指标、能力指标以及评估工具的使用方法。重点在于理解如何衡量模型生成答案的准确性、相关性，以及检索内容的质量。可以利用评估工具对RAG系统进行全面分析，从而为模型的优化提供数据支持。

学习资源

1）使用合成数据和 LLM 作为裁判评估 RAG

https://huggingface.co/learn/cookbook/zh-CN/rag_evaluation

2）一次搞懂RAG评估，三个角度LangChain，LlamaIndex，RAGAS

https://www.bilibili.com/video/BV1aZ421W7DB/

经典面试题（更多面试题）

1）请解释在RAG系统中，答案的“忠实度”和“相关性”有何不同？在实际项目评估中，如何分别度量这两个指标？

2）你如何评估一个RAG系统是否具备良好的信息整合能力？

3）在评估RAG系统的鲁棒性时，你会设计哪些实验来检测其对噪声的容忍能力？

4）一个RAG系统频繁生成带有负面信息的回答，你会如何定位问题并使用哪些指标或工具进行优化？

RAG项目（7天）

知识

- RAGFlow
- FastGPT
- QAnything
- LangChain-chatchat
- GraphRAG

学习建议

前面学习的都是RAG的理论知识，下面可以深入去实践RAG项目了，通过实际的开源项目，可以将理论知识应用于实践，深化对 RAG 技术的理解。通过阅读这些项目的源码，可以了解不同 RAG 框架的实现细节和设计思路。建议选择一个与自己目标最契合的项目，深入研究其架构和代码实现，并尝试进行本地部署和测试。

阶段3：大模型Agent应用架构

LangChain（15天）

知识

- 什么是LangChain
- LangGraph提示词管理，监控，链定义和管理
- LangChain和Tavily检索
- LangChain的核心组件
    - Chat models VS LLMs
        - 流式输出
        - token 追踪
        - 结构性输出
    - 模型I/O封装
        - Prompts模版
        - 自定义Prompts模版
        - 序列化模版
    - 数据连接
        - 文本向量化实现方式

编程导航(codefather.cn)

        - 向量数据库
            - Chroma
            - ES
            - FAISS
            - Milvus
        - 文档转换切割
    - Memory记忆封装
        - 内置链
        - Memory 工具使用
        - 为链增加Memory
        - 多轮对话的历史记录
    - 链（chain）
        - LCEL表达式
        - LCEL Runnable 协议设计与使用
        - LCEL 进阶使用：整合复杂逻辑的多链
        - LCEL添加记忆
        - LCEL中chain与prompt结合

学习建议

学习 LangChain 框架对于大模型应用开发非常重要。它是一个开源框架，它简化了与大型语言模型（LLM）的集成，可以帮助你快速构建复杂的 AI 应用。你可以先了解 LangChain 的核心概念，如提示词管理、链的定义和管理等，这些是构建应用的基础。接着，深入学习 LangChain 的核心组件，包括 Chat Models 与 LLMs 的区别、模型 I/O 封装、数据连接、Memory 记忆封装以及链（Chain）的使用。这些组件是 LangChain 的精髓，掌握它们将使你能够灵活地构建和优化应用。学习过程中，不用死磕底层，先跑通几个Demo（比如本地知识库问答），再慢慢深入。学到能独立用LangChain接API、处理数据、搭出可用的AI工具就够用了，细节可以边做边补。

学习资源

1）LangChain官方文档（Python）

https://python.langchain.com/docs/introduction/

2）LangChain中文文档

https://www.langchain.com.cn/

3）LangChain大模型全套教程

https://www.bilibili.com/video/BV1BgfBYoEpQ

4）LangChain 教程

https://www.langchain.asia/

5）LangChain 的中文入门教程 Topics

https://github.com/liaokongVFX/LangChain-Chinese-Getting-Started-Guide

经典面试题（更多面试题）

1）LangChain 是什么？它的核心功能和特点是什么？请简要解释它如何帮助构建基于大语言模型的应用。

2）解释LangChain框架中的Chain和Agent概念，并举例说明各自的应用场景

3）使用LangChain时，如何实现多路召回结果的动态权重分配？

4）请描述使用LangChain构建一个文档问答系统的关键技术组件及实现步骤

编程导航(codefather.cn)

5）LangChain 中的 Memory 组件如何工作？它如何帮助大语言模型保持上下文并支持多轮对话？

LlamaIndex（5天）

知识

- LlamaIndex 是什么
- LlamaIndex 的优势和劣势
- LlamaIndex 与RAG检索增强联合应用实践
- LlamaIndex与LangChain对比分析

学习建议

学习LlamaIndex 能帮助你将LLM与特定领域的数据相结合，构建更智能的应用程序。可以先读一些文档，了解LlamaIndex的基本概念和使用模式。然后，通过实践教程，尝试搭建一个简单的文档问答系统，加深对其核心组件的理解。

学习资源

1）LlamaIndex 官方文档

https://docs.llamaindex.ai/en/stable/

2）LlamaIndex 使用指南

https://llama-index.readthedocs.io/zh/latest/guides/primer.html

3）LlamaIndex零基础全套课程

https://www.bilibili.com/video/BV1JDpFeEEay/

4）LlamaIndex 教程

https://llama-index.readthedocs.io/zh/latest/guides/tutorials.html

经典面试题（更多面试题）

1）LlamaIndex 是什么，它的主要功能和目标是什么？

2）LlamaIndex 如何构建文档索引？你能描述一下它的索引结构吗？

3）在 LlamaIndex 中，如何处理和管理大量非结构化数据？

4）在 LlamaIndex 中，如何对文档进行预处理，以确保索引的效率和检索质量？

5）LlamaIndex 如何处理复杂的查询和多步骤推理任务？

Agent（20天）

知识

- Agents关键技术分析
    - Agents 介绍
    - Agents流程、决策图
    - 规划 (Planning)
        - 子任务拆解
        - 反思与改进
    - 记忆 (Memory)
    - 工具使用 (Tools)
        - 预制工具 (Tool)
        - 预制工具集 (Toolkits)

编程导航(codefather.cn)

        - 自定义工具
    - 执行 (Action)
- Function Calling
    - Function Calling的诞生背景
    - 如何理解Function Calling
    - Function Calling的实现过程
    - 远程Function Calling调用
    - 支持Function Calling的国产模型
- Agent认知框架
    - ReAct思考-行动-观察
    - Plan-and-Execute
    - Self-Ask
    - Thinking and Self-Reflection
- 多Agent系统
    - AutoGPT快速打造智能体
    - CAMEL策略
    - AutoGen
    - MetaGPT

学习建议

学习Agent能让大模型从“只会聊天”变成“能干活”的智能助手。建议从LangChain这类框架入手，先写个能查天气或订票的Demo，再慢慢加复杂功能（比如多Agent协作）。学到能独立设计一个能自动完成任务的Agent就够用了，比如客服自动回复系统或者数据分析助手等等。

学习资源

1）Agent教程

https://github.com/datawhalechina/agent-tutorial

2）AI Agent 视频讲解

https://www.bilibili.com/video/BV1dxm6YPEDB

3）AI Agent入门到精通实战教程

https://www.bilibili.com/video/BV1SqKHeUEm5/

经典面试题（更多面试题）

1）什么是Agent？在AI应用中，Agent的核心作用是什么？

2）Agent系统中，如何进行子任务拆解和反思？它们如何帮助提高决策效率？

3）Agent中的记忆(Memory)如何作用于系统的学习和决策？

4）在Agent系统中，如何实现远程Function Calling？有哪些常见的技术实现方式？

5）如何通过规划和执行(Plan-and-Execute)来优化Agent的任务执行效率？

可视化开发框架/Agent IDE（10天）

知识

- GPTs

编程导航(codefather.cn)

    - GPTs
    - Assistants API
        - 应用场景
        - Assistants thread和messages
    - 原生API
    - 开源大模型
- Coze扣子
    - Coze
    - Coze基础
        - Coze概述
        - AI Agent的人设
        - AI Agent插件系统
        - AI Agent工作流
        - 知识库、数据库和变量-AI Agent的记忆
        - AI Agent发布
    - Coze实操
        - 构建知识库
- Dify 开源的应用编排工具
    - Dify
    - Dify基础架构
    - Dify实操

学习建议

学习完AI Agent 之后就可以实操了，这些工具能让你不用写太多代码就能快速搭建AI应用。可以先了解这3个框架的特点，然后可以使用他们搭建个AI应用。

学习资源

1）【教程】快速上手 OpenAI GPTs：分分钟创建你的专属 GPT

https://www.bilibili.com/video/BV1gG411X7q7/

2）Coze零基础视频教程

https://www.bilibili.com/video/BV1AWQzYHEaU/

3）Dify搭建简单的知识库问答工作流

https://www.bilibili.com/video/BV1M29PYiEHx/

4）Dify官方文档

https://docs.dify.ai/zh-hans

经典面试题（更多面试题）

1）在使用Dify进行开发时，如何进行应用编排？简要描述Dify的实操步骤。

2）如何使用Assistants API来构建AI助手

3）如何定义AI Agent的人设？在人设设计中，AI Agent的任务和目标如何影响其行为？

4）在Coze中，如何构建和管理知识库？它如何支持AI Agent的记忆功能？

编程导航(codefather.cn)

阶段4：大模型微调与私有化部署

Transformer（10天）

知识

- Transformer结构理解
- Transformer 模型总体架构
- 理解Self-Attention
- 理解Encoder与Decoder
- Multi-head Attention
- 不同Decoding方法

学习建议

学习大模型应用开发，Transformer是必须跨过的坎儿，因为它是所有大模型的"心脏"。重点先搞懂三个核心：自注意力机制（为啥模型能同时关注所有词）、编码器-解码器结构（怎么把输入变成输出）、位置编码（为啥不用RNN也能记住顺序）。建议边学边动手，比如用PyTorch从头实现一个迷你Transformer（不用太复杂，能跑通文本分类就行），再对比Hugging Face的现成API感受差异。学到能说清楚BERT和GPT的区别、能自己调通一个微调任务就够用了。

学习资源

1）强烈推荐！台大李宏毅自注意力机制和Transformer详解！

https://www.bilibili.com/video/BV1v3411r78R

2）Transformer从零详细解读

https://www.bilibili.com/video/BV1Di4y1c7Zm

3）Transformer 快速入门

https://transformers.run/

4）图解Transformer

https://zhuanlan.zhihu.com/p/347904940

5）Transformer 使用教程

https://huggingface.co/docs/transformers/zh/quicktour

经典面试题（更多面试题）

1）聊一聊 Transformer 的架构和基本原理。

2）Transformer 的哪个部分最占用显存？

3）讲一下你对 Transformer 的 Encoder 模块的理解

4）Transformer 中，Decoder 阶段的多头自注意力和 Encoder 阶段的多头自注意力是相同的吗？

5）Transformer 和 LLM 有哪些区别

开源模型（20天）

知识

- 国外开源模型和框架
    - Llama
    - Falcon
    - vLLM

    - OpenLLM
    - Ollama
    - Mistral
- 国内开源模型
    - ChatGLM
    - Qwen
    - Deepseek
    - Baichuan
    - Moss
    - InternLM

学习建议

可以先搞懂几个主流模型的特点，然后本地部署一下，可以优先把主流的国外模型和国内模型都跑通一遍，比如用 Ollama 跑个 Llama3、用 vLLM 部署一个 ChatGLM，重点是理解它们的模型结构、推理速度优化策略、部署环境依赖这些工程细节，未来你在做模型服务端开发、评估切换模型时才不会一头雾水。

学习资源

1）llama3 视频教程

https://www.bilibili.com/video/BV1bD62YdE9A

2）部署Ollama教程

https://www.bilibili.com/video/BV13e1jY9EmZ/

3）动手学Ollama

https://datawhalechina.github.io/handy-ollama/#/

4）Dify 模型接入

https://docs.dify.ai/zh-hans/development/models-integration

Fine-Tuning（模型微调）（15天）

知识

- 模型微调介绍
- 如何选择合适的基座模型
- 数据集的收集与预处理
    - 数据增强
    - 数据清洗
    - 数据去重
- 微调训练框架
    - Hugging Face Transformers
    - PyTorch
    - DeepSpeed

学习建议

开源模型的微调是比较关键的，重点先搞懂三件事：选基座模型（中文任务优先选ChatGLM3或Qwen，英文选Llama3）、处理数据（清洗比增强更重要，别让脏数据带偏模型）、跑通微调流程（先用Hugging Face

编程导航(codefather.cn)

Transformers+LoRA试手，再尝试DeepSpeed加速）。建议从简单的分类任务开始，比如用ChatGLM3微调一个工单分类器，数据集不用大，几百条高质量数据就能看到效果。学到能独立完成一个业务场景的微调就够用了。

学习资源

1）Transformer 使用教程

https://huggingface.co/docs/transformers/zh/quicktour

2）deepSpeed 教程

https://deepspeed.org.cn/getting-started/

3）Pytorch 教程

https://www.runoob.com/pytorch/pytorch-tutorial.html

经典面试题（更多面试题）

1）请解释大模型微调(Fine-tuning)的原理，并说明在什么业务场景下需要微调而不是直接使用基础模型？

2）请解释如何使用 TensorFlow 或 PyTorch 构建和训练一个深度学习模型。

3）了解哪些大模型微调技术？

4）在进行Fine-Tuning时，如何选择适合的预训练模型？

5）如何在微调过程中使用不同的学习率策略？

PEFT fine-turnig（参数高效微调）（20天）

知识

- PEFT fine-turnig 介绍
- PEFT 主流技术
  - Adapter Tuning
  - Prompt Tuning
  - Prefix Tuning
- LoRA 低秩适配微调
  - 算法原理
  - 性能效果
- LoRA 的改进和扩展
  - AdaLoRA自适应权重矩阵微调算法解析
  - QLoRA量化低秩适配微调算法解析
  - LongLoRA长上下文低秩适配微调算法解析
  - SLoRA低秩适配微调算法解析
- P-Tuning V2
  - 原理介绍

学习建议

这个阶段主要是让你在不需要庞大计算资源的情况下，对大模型进行高效微调，适应特定任务。首先需要理解PEFT的主要技术，如Adapter Tuning、Prompt Tuning和Prefix Tuning，掌握它们的原理和适用场景。接着，深入学习LoRA（Low-Rank Adaptation），这是目前最通用、效果最好的微调方法之一。此外，可能需要了解LoRA的改进和扩展，

如AdaLoRA、QLoRA、LongLoRA和SLoRA，它们在不同场景下提供了更灵活的微调策略。这个阶段有很多的专业名词，会有写晦涩难懂，需要在网上看一些文档，然后再结合实际项目去理解，这样会容易点。

学习资源

1）Hugging Face PEFT官方文档

https://huggingface.co/docs/peft/en/index

2）LoRA实战教程

https://github.com/hiyouga/LLaMA-Factory

3）微调方案介绍

https://datawhaler.feishu.cn/wiki/TyQZw9lZSiN1V5kTKlocgJOvnag

4）基于 Qwen2 大模型微调技术详细教程

https://www.cnblogs.com/obullxl/p/18312594/NTopic2024071801

5）大模型参数高效微调技术原理和实战

https://github.com/SwordHG/LLM-PEFT-

经典面试题（更多面试题）

1）LoRA 的原理了解吗？

2）聊聊你对 Q-LoRA（Quantized Low-Rank Adaptation）的理解。

3）什么是参数高效微调（PEFT），它与传统的Fine-Tuning有何区别？

4）在PEFT中，如何选择要微调的参数或模块？

5）PEFT在处理大规模预训练模型时如何优化内存和计算消耗？

Quantization（量化）（10天）

知识

- 模型显存占用与量化技术
    - 微调中GPU算力测算算法
    - GPU芯片性能分析
    - 模型运行算力要求
- Transformers 原生支持的大模型量化算法
    - PTQ：训练后量化
    - QAT：量化感知训练
- AWQ：激活感知权重量化算法
- GPTQ：专为 GPT 设计的模型量化算法

学习建议

量化在大模型开发学习中也是比较重要的，通过量化技术，可以显著减少模型的内存占用和计算需求，同时尽量保持模型的性能。建议可以从理解模型量化的基本概念开始，掌握训练后量化（PTQ）和量化感知训练（QAT）的原理，了解它们各自的适用场景和优缺点。接着，深入研究一些先进的量化算法，如GPTQ和AWQ，理解它们如何在保持模型精度的同时进一步压缩模型大小。重点在于理解这些算法的核心思想和实现方式，以及它们在实际应用中的效果。可以通过阅读相关论文和实践代码示例，你可以更好地掌握这些技术。

编程导航(codefather.cn)

学习资源

1）量化感知训练（Quantization-aware-training）探索-从原理到实践

https://zhuanlan.zhihu.com/p/548174416

2）GPTQ算法详解

https://zhuanlan.zhihu.com/p/18714878738

3）AWQ量化技术解析

https://zhuanlan.zhihu.com/p/681578090

4）GPTQ官方实现

https://github.com/IST-DASLab/gptq

5）吴恩达《深入模型量化|Quantization in Depth》

https://www.bilibili.com/video/BV1kw4m1X7Bi/

经典面试题（更多面试题）

1）什么是模型量化，为什么在深度学习中需要使用量化技术？

2）量化如何影响深度学习模型的显存占用和计算效率？

3）PTQ（训练后量化）与QAT（量化感知训练）有什么区别？

4）量化技术对GPU芯片性能的影响有哪些？

5）如何选择适合的量化算法，PTQ与QAT在不同场景下的适用性如何？

语言模型训练数据（5天）

知识

- 数据来源
  - 通用数据
  - 专业数据
- 数据处理
  - 低质过滤
  - 冗余去除
  - 隐私消除
- 数据影响分析
  - 数据规模影响
  - 数据质量影响
  - 数据多样性影响
- 开源数据集合
  - Pile
  - ROOTS
  - RefinedWeb
  - SlimPajama

学习建议

编程导航(codefather.cn)

在大模型中，数据的质量、来源和多样性直接影响模型效果，这个阶段你需要学习如何从通用和专业领域收集高质量的数据，掌握数据清洗、去重和隐私保护等预处理技术。此外，了解数据规模、质量和多样性对模型训练的影响，也要了解一些开源数据集的特点和应用场景。

学习资源（更多面试题）

1）RefinedWeb数据集论文（含清洗方法）

https://arxiv.org/abs/2306.01116

2）SlimPajama数据集介绍及其处理方法

https://huggingface.co/datasets/cerebras/SlimPajama-627B/blob/main/README.md

3）大模型预训练中文语料清洗及质量评估

https://github.com/jiangnanboy/llm_corpus_quality

经典面试题

1）什么是通用数据和专业数据，它们在训练语言模型时的作用有什么区别？

2）数据质量如何影响语言模型的性能，如何进行低质数据的过滤？

3）如何处理训练数据中的噪声（如无意义文本或乱码）？具体有什么技术或方法？

大语言模型评估（5天）

知识

- 模型评估介绍
- 大语言模型评估体系
    - 知识与能力
    - 伦理与安全
    - 垂直领域评估
- 大语言模型评估方法
    - 评估指标
    - 评估方法
- 大语言模型评估实践
    - 基础模型评估
    - SFT/RL 模型评估

学习建议

这个阶段你需要理解模型评估的基本概念，包括质量指标（如BLEU、ROUGE、METEOR等）和能力指标（如准确率、召回率、F1分数等），以及如何使用这些指标来衡量模型的表现。此外，熟悉常用的评估工具和框架，如GLUE、SuperGLUE等，这会有助于你在实践中有效地评估模型。

学习资源

1）Hugging Face评估教程

https://huggingface.co/docs/evaluate/index

2）大模型安全评测

https://github.com/thu-coai/Safety-Prompts

编程导航(codefather.cn)

经典面试题（更多面试题）

1）大语言模型评估的主要维度是什么？如何平衡这些维度的评估？

2）什么是 SFT（监督微调）和 RL（强化学习）模型的评估方法？它们的评估标准有何不同？

3）在评估大语言模型时，知识与能力的评估如何进行？有哪些常见的评估指标？

Multimodal（多模态）（20天）

知识

- 什么是多模态模型
- 多模态的应用场景
- AIGC是什么
- AIGC的应用场景
- 图像生成算法
- 基于扩散模型的算法
- DALLE-3与Midiourey
- Stable Diffusion与ControlNet
- 语音生成技术
- 主流TTS技术

学习建议

多模态（Multimodal）技术在大模型应用开发中至关重要，因为它使模型能够处理和整合多种数据类型，如文本、图像、音频和视频，拓宽了应用场景的广度。重点先搞懂多模态的核心概念（比如CLIP、BLIP这类模型如何对齐不同模态的数据）以及应用场景，再动手跑通一个端到端的多模态应用流程，比如用Hugging Face的Transformers库实现一个简单的图文匹配demo，能独立完成一个业务场景的多模态应用。然后可以了解下一些算法，比如基于扩散模型的算法等，知道他们的原理和技术细节，可以多看看论文和解析，这样也能更快理解。

学习资源

1）多模态大模型原理

https://www.bilibili.com/video/BV1kT411o7a6/

2）Stable Diffusion全套教程

https://github.com/ai-vip/stable-diffusion-tutorial

3）Midjourney入门使用教程

https://x1d5ow2zb0f.feishu.cn/wiki/TOFnwt4lwiA4R1kMGOgcwbkqn6d

4）扩散模型详解

https://zhuanlan.zhihu.com/p/662015724

经典面试题（更多面试题）

1）什么是多模态模型？它与单模态模型有何区别？

2）AIGC（人工智能生成内容）的概念是什么？它在实际应用中有什么重要作用？

3）多模态模型如何处理不同模态的数据（如文本、图像、语音等）？

4）请简述Stable Diffusion的原理，并说明其相较于传统的生成对抗网络（GAN）有哪些优势。

学习资源

编程导航(codefather.cn)

视频教程

1）李沐讲AI（动手学深度学习在线课程）

课程：https://courses.d2l.ai/zh-v2/

视频：https://space.bilibili.com/1567748478?

2）马士兵-AI大模型全套教程

https://www.bilibili.com/video/BV128cUe6EU2/

3）AI大模型零基础全套教程

https://www.bilibili.com/video/BV1uNk1YxEJQ

4）【吴恩达大模型LLM】系列教程

https://www.bilibili.com/video/BV1F8ftYPEgg

5）【清华NLP】刘知远团队大模型公开课

https://www.bilibili.com/video/BV1UG411p7zv

6）斯坦福NLP cs224n

https://web.stanford.edu/class/cs224n/

7）动手学深度学习

https://zh.d2l.ai/

8）神经网络与深度学习

https://nndl.github.io/

9）台大李宏毅-机器学习

https://speech.ee.ntu.edu.tw/~hylee/ml/2023-spring.php

10）吴恩达 x Open AI ChatGPT 提示工程教程

https://www.bilibili.com/video/BV1s24y1F7eq/?vd_source=1c91f2eccd0fec95bb790e7f6942e73c

项目

1）手把手教学从头build LLM

https://github.com/rasbt/LLMs-from-scratch

2）LlamaFactory: 一键式LoRA微调、全参SFT、增量预训练框架

https://github.com/hiyouga/LLaMA-Factory

3）一个通用的pytorch模型训练模版工具

https://github.com/lyhue1991/torchkeras/

4）学习LLM的非常好的项目

https://github.com/karpathy/

编程导航(codefather.cn)

5）DeepSeek-R1 的复刻

https://github.com/huggingface/open-r1/

6）蒸馏的 QwQ 的数据实现的 o1-like 模型。

https://github.com/NovaSky-AI/SkyThought

7）R1 多模态的复刻项目

https://github.com/EvolvingLMMs-Lab/open-r1-multimodal

书籍&课程

1）面向开发者的 LLM 入门教程，吴恩达大模型系列课程中文版

https://github.com/datawhalechina/llm-cookbook

2）大规模语言模型：从理论到实践

https://intro-llm.github.io/

3）Huggingface Transformers官方课程

https://huggingface.co/learn/nlp-course/chapter1/1

4）Transformers快速入门（快速调包BERT系列）

https://transformers.run/

5）神经网络与深度学习

https://nndl.github.io/

6）LLM 资料库

https://github.com/morsoli/llm-books

7）大模型基础

https://github.com/datawhalechina/so-large-lm

8）基于《斯坦福大学大规模语言模型课程》打造的大模型理论教程

https://datawhalechina.github.io/so-large-lm

9）动手学大模型应用开发

https://github.com/datawhalechina/llm-universe

10） 基于MetaGPT的多智能体入门与开发教程

https://github.com/datawhalechina/hugging-multi-agent

11）Transformers 教程

https://transformers.run/

技术分析文章

1）图解Transformer

编程导航(codefather.cn)

https://jalammar.github.io/illustrated-transformer/

2）GPT2图解

https://jalammar.github.io/illustrated-gpt2/

3）GPT3分析

https://jalammar.github.io/how-gpt3-works-visualizations-animations/

4）如何合成微调数据

https://eugeneyan.com/writing/synthetic/

5）大模型量化解析

https://newsletter.maartengrootendorst.com/p/a-visual-guide-to-quantization

6）OpenAI 的思考模型最佳实践

https://platform.openai.com/docs/guides/reasoning-best-practices

知识库

1）鱼皮的 AI 知识库

https://ai.codefather.cn/

2）AGI 掘金知识库

https://agijuejin.feishu.cn/wiki/UvJPwhfkiitMzhkhEfycUnS9nAm

3）GeekAGI知识库

https://geek-agi.feishu.cn/wiki/B9rYwwg6xidZYJkbrlscxTQFnOc

4）Open 1 +X AI通识课

https://datawhaler.feishu.cn/wiki/X9AVwtmvyi87bIkYpi2cNGlIn3v

5）一站式AI产品经理入门指南

https://v11enp9ok1h.feishu.cn/wiki/KiIvwdFOciiqqNkwKzTcmn88ndL

6）思源AIGC创新库

https://a6o1uit4yt.feishu.cn/wiki/NgBowEp2HivTGPkJEEmcBAS1n7b

论文报告

1）DeepSeek R1

https://github.com/deepseek-ai/DeepSeek-R1/blob/main/DeepSeek_R1.pdf

2）Llama技术报告

https://arxiv.org/abs/2407.21783

3）Mixtral-8X7B-MOE

https://mistral.ai/news/mixtral-of-experts

编程导航(codefather.cn)

4）70B模型训练细节

https://imbue.com/research/70b-intro/

5）Qwen技术报告

https://arxiv.org/abs/2309.16609

6）面壁智能的详尽技术报告

https://arxiv.org/abs/2404.06395

7）VidProM: 文生视频提示数据集

https://arxiv.org/abs/2403.06098

8）语言模型的算法进展

https://arxiv.org/abs/2403.05812

9）大模型推理速度计算和瓶颈分析

https://arxiv.org/abs/2405.08944

10）Prompt 工程综述

https://arxiv.org/abs/2407.12994

11）高级 RAG 优化方法

https://arxiv.org/abs/2407.21059

12）Kimi K1.5 推理模型

https://arxiv.org/abs/2501.12599v1

13）DeepSeek Math

https://arxiv.org/abs/2402.03300

14）中文蒸馏数据集

https://huggingface.co/datasets/Congliu/Chinese-DeepSeek-R1-Distill-data-110k

15）Qwen2 技术报告

https://arxiv.org/abs/2407.10671

16）LLM 评估，不应忽视非确定性

https://arxiv.org/abs/2407.10457

> *本资源来自编程导航：https://codefather.cn*
>
> *推荐更多免费学编程资源：*
>
> 1. *编程导航学习网站：学编程、做项目、拿 Offer！*
> 2. *企业高频面试题库：开始刷题，面试遇原题！*
> 3. *精选简历模板大全：1 分钟搞定简历！*
> 4. *AI 资源导航网站：获取最新 AI 黑科技！*
> 5. *1 对 1 模拟面试：随时随地提升面试能力*

编程导航(codefather.cn)