黑马程序员
www.itheima.com

零基础学AI，来黑马程序员

AI大模型开发

Vibe Coding

OpenClaw

V7.5

培养能落地、懂业务、
强技术的大模型开发工程师

黑马重磅推出AI大模型应用开发V7.5课程

培养企业紧缺的大模型应用开发工程师

优势1 体系化AI进阶学习路径，覆盖AI开发全链路

完整的学习地图	语言基础	应用开发			算法进阶
	Python基础	Transformer原理解析	大模型微调	RAG应用	智能体开发	大模型蒸馏

算法强基 + 应用为王

聚焦企业级应用落地，同时夯实算法根基，避免“调包侠”困境，培养能开发、懂原理、可优化的综合型人才。

主流平台全覆盖	Dify、coze、LangChain、LangGraph、Ollama、vLLM
模块化项目周期	提示词工程 → Coze/Dify项目 → RAG系统 → Agent开发
从本地部署到云原生	Ollama/vllm（本地模型起步）→ 逐步进阶 → Docker+Kafka+Redis（企业级部署）→ 平滑过度 → 生产环境

优势2 四大热门方向，精准狙击企业需求

课程匹配AI时代主流的大模型开发岗位，破解企业4大AI落地痛点

智能体方向

基于Coze/Dify开发企业级智能体，实现技术面试助手、智能客服等应用，结合RAG和ASR/TTS技术解决业务自动化需求

RAG方向

利用LangChain+向量数据库构建企业级检索增强系统，解决物流/人力资源等场景的模型幻觉问题，实现精准知识库问答与推荐

大模型微调方向

聚焦生产落地，以LoRA/QLoRA微调+GPTQ量化技术优化任务性能，结合DeepSpeed量化部署满足企业定制模型需求

多模态大模型方向

主要应用于需要处理多种类型数据的场景，如视觉问答、图文生成、语音识别与合成等

优势3 Vibe Coding × OpenClaw 强强融合，课程与市场零时差

掌握下一代智能开发范式，技能一步到位不脱节，以最新技术栈赋能实战，打造核心竞争力

独立开发企业级OpenClaw，对接企业系统

课程教授如何利用 OpenClaw 理念，让大模型具备“手”和“眼”，自主调用搜索、数据库、API 等外部工，构建真正的Agentic Workflow（智能体工作流）。



人机协作的“指挥官”思维

学员将掌握 Prompt Engineering进阶版(Context Management)、AI代码审查、以及多智能体协作管理，成为 AI时代的技术指挥官。



自研企业级 OpenClaw 框架 | 构建 Agentic Workflow | 开发范式与行业趋势对齐

优势4 与头部科技企业深度共建，打造“零距离”就业竞争力

大厂 × 企业联合打磨：萃取前沿实战技术，打造经实战验证、直击实际问题的高效课程

企业级技术标准

联合讯飞星火、腾讯云、阿里云等大厂打磨课程，萃取前沿实战经验，内容均经实战验证、直击问题核心。

顶级资源赋能

依托阿里 PAI、腾讯云等平台提供 GPU 算力支持，降低硬件门槛，直通工程师同款技术环境。

大模型权威证书

与科大讯飞联手打造四大认证证书 —— Prompt 工程师认证、微调工程师认证、智能体工程师认证及RAG工程师认证。

每年更新15%以上核心模块

保障学习内容的前沿性与适配性

合作企业：讯飞星火、腾讯云、阿里云、VirtAI Tech



优势5 企业级多场景项目库，让你成为解决复杂问题的实战专家

深度融合电商、物流、新媒体、人力资源等企业真实业务场景，构建覆盖多行业、多场景的综合性技术栈体系

10 个企业级项目实战 | **6** 大行业领域覆盖

旅行智能助手

大模型让你的出行更加高效和便捷！

旅游 Agent

SmartRecruit简历推荐项目

大模型让HR简历匹配更精准！

人力资源 Agent RAG

EduRAG项目

解决垂类领域模型幻觉问题，让大模型回答更精准

教育 RAG

微博文本信息抽取项目

通过大模型微调，让业务问题回答更精准！

新媒体 微调

Coze智能面试助手开发项目

Coze低代码平台，更快落地业务智能体！

教育 Agent

云客服*工业级智能服务平台 NEW

让5个AI专家24小时守护您的云服务

工业 Agent

星通 * 通用智能体项目 NEW

通用智能体平台，大模型帮你办公、数据分析

通用 Agent

基于大模型搜索推荐项目 NEW

大模型让海量“职位”搜索更精准

人力资源 微调

电商商品聚合多模态项目 NEW

互联网“千万级”电商商品知识图谱构建

电商 多模态

EduAgent智能教育助手项目 NEW

构建企业级教育AI Agent系统

教育 Agent

AI大模型开发（Python）V7.5课程

大模型应用开发 26天

1	**大模型开发入门** 大模型开发入门	8天
2	**大模型开发语言进阶** Python高级	8天
3	**大模型智能体平台开发** 提示词工程 / 智能体开发（Coze+Dify） / 【项目】基于Coze的技术面试助手 / 【项目】基于Dify实现Agent开发应用	10天

大模型智能体开发 37天

4	**大模型核心开发技术** 机器学习/深度学习 / Pytorch框架 / Transformer基础 / 【项目】NewsCompass投满分项目	17天
5	**RAG应用开发** LangChain框架 / 【RAG项目】基于职业教育领域RAG智慧问答系统 2选1 / 【RAG项目】基于人力资源场景的RAG的简历推荐系统 2选1	10天
6	**智能体高级开发** 【ReAct智能体项目】InsightScan智扫通Agent项目 / 【多智能体项目】基于A2A的SmartVoyage旅行智能助手 2选1 / 【多智能体项目】基于多场景的Agent智能工单项目 2选1	10天

大模型定制开发 15天

8	**大模型核心运行机制** 大模型Transformer架构 / 大模型迁移学习 / 大模型主流模型运行机制	5天
7	**大模型微调开发** 大模型核心运行机制 / 大模型微调开发基础 / 【项目】【LoRA微调】微博文本信息抽取项目 3选2 / 【项目】QWen微调文本摘要项目 3选2 / 【项目】基于中医药知识图谱项目 3选2	10天

大模型算法进阶 12天

9	**CV图像分析** 计算机视觉背景 / 图像分析特性 / 图像分类 / 图像分割	6天
10	**全模态大模型** 多模态大模型应用开发 / CV图像分析	6天

大模型应用开发

大模型开发入门

课时：8天

课程亮点

- 涵盖基础知识：包括 Python 基本语法、数据类型（如字符串、列表、元组、字典等）、控制流（条件语句、循环等），为进一步学习打下坚实基础
- 注重实践操作：通过实际案例和项目练习，让学生能够将理论知识应用到实际编程中，提升动手能力和解决问题的能力
- 培养逻辑思维：帮助学生学会如何分解问题、设计算法，以及通过编程实现解决方案，从而有效培养逻辑思维能力

能力目标

- 掌握搭建聊天机器人的步骤
- 掌握搭建聊天机器人必备语言和工具
- 掌握大模型必备Python语言的基本语法
- 掌握分支结构的用法
- 掌握循环结构的用法
- 掌握容器类型相关的概述
- 掌握字符串的相关操作
- 掌握容器类型的遍历
- 掌握列表-字典的相关操作
- 掌握函数的各种参数
- 掌握函数的引用相关
- 独立完成匿名函数的编写和使用
- 掌握文件的相关操作
- 掌握异常的处理方式
- 熟悉Streamlit框架搭建页面

课程大纲

模块	技术点	详细知识点
AI大模型入门与应用	AI大模型项目介绍和环境搭建	AI大模型搭建聊天机器人需求分析；AI大模型搭建聊天机器人步骤和流程；AI大模型搭建聊天机器人必备语言和工具项目环境搭建
	AI大模型入门与应用	通用AI大模型和垂直领域大模型应用实操，包括AI赋能办公、运营、文生图多模态等多种应用场景，帮助学生熟悉AI大模型行业落地场景，为后续开发提供支持
AI大模型语言基础	大模型必备Python基础语法	学习大模型必备Python语言；Python解释器和Pycharm开发工具安装；注释和定义变量；标识符和关键字以及命名规范；输入和输出函数；算数运算,比较运算,逻辑运算,赋值运算
	大模型必备Python控制语句	分支语句if elif else；循环结构while for；跳转语句break和continue
	大模型必备Python容器	循环嵌套-99乘法表；循环案例-猜数字游戏；不同容器的介绍和定义；索引操作；切片操作；字符串的常见功能；容器的遍历；列表详解；元组详解；字典容器的使用；容器类型嵌套案例-随机分配办公室；容器类型-公共的运算符和方法
	大模型必备Python函数	函数入门；函数的参数和返回值；变量作用域；函数的多种参数；拆包和变量交换；引用和匿名函数；递归实操；【综合案例】斐波那契数列
	大模型必备Python文件和异常处理	文件的读写入门；中文乱码和路径问题；文件复制；os模块；with-open语法；异常处理方式；导入包和模块
聊天机器人搭建	智能聊天机器人搭建	Streamlit框架；Python调用Ollama私有化部署大模型；云端大模型API调用

大模型开发语言进阶

课时：8天

课程亮点

- 涵盖Python面向对象编程、高阶语法、网络编程及多任务编程，为大模型应用开发提供扎实的编程基础。

能力目标

- 掌握面向对象编程思想
- 独立运用面向对象思想完成指定需求
- 掌握深拷贝和浅拷贝代码原理
- 独立完成面向对象版–学生管理系统
- 掌握闭包，装饰器的用法
- 独立完成网编案例代码实现
- 掌握多进程，多线程相关代码实现
- 掌握上下文管理器对象的使用
- 掌握生成器，迭代器的用法
- 理解正则表达式的相关运用
- 掌握MySQL基本操作
- 掌握Pandas基本操作

课程大纲

模块	技术点	详细知识点
Python面向对象进阶	面向对象入门	面向对象和面向过程；类和对象的区别；定义类和属性；定义方法和魔法方法；面向对象–案例；【实战案例】面向对象综合实战案例
	面向对象进阶	继承的使用；私有权限；类属性和对象属性；类方法和静态方法；面向对象版–学生管理系统；【实战作业】面向对象版–学生管理系统（采取部分实战）
Python高阶语法	闭包+装饰器	深拷贝，浅拷贝详解；闭包详解；装饰器详解；【实战案例】装饰器实战案例
	网编+多进程入门	网编相关概述介绍；网编案例–客户端发送文件到服务器端；并行和并发详解；多进程–代码实现；【实战案例】网编案例–客户端和服务器端交互
	多线程详解	多线程代码实现；守护线程详解；互斥锁详解；线程同步详解；上下文管理器详解；Json数据文件读取和处理；【实战案例】Json数据文件读取和处理
	生成器,正则详解	生成器详解；迭代器详解；正则表达式详解；【实战案例】正则表达式文本匹配综合案例
MySQL	数据库介绍、MySQL数据库的安装使用	数据库基本操作；数据库概念和作用；MySQL数据类型；数据完整性和约束
	数据表操作	数据库；表操作命令；表数据操作命令
	基本查询操作	where子句；分组聚合；连接查询；外键的使用；PyMySQL
Pandas	Numpy	Numpy基础概念与操作；运算优势；数组的属性；数组的形状；Numpy实现数组基本操作
	Pandas的DataFrame、数据清洗、数据读取	Pandas统计分析；Pandas数据整理；Pandas透视表；Pandas可视化

大模型智能体平台开发

课时：10天

金融行业动态风向评估

项目介绍

- 基于Zero-shot零样本学习能力，通过DeepSeek/QWen/ChatGLM模型对金融领域数据进行分类、信息抽取、文本匹配，更好的解决业务问题。

能力目标

- 能够理解和应用提示词工程原理
- 掌握优化技巧并完成金融业务场景的实际问题解决

解决方案

- 提示词撰写解决方案
- 信息抽取提示词解决方案
- 文本分类提示词解决方案
- 文本匹配提示词解决方案

主讲知识点

- 大模型发展过程、提示词介绍及撰写介绍、提示词优化方法、基于Ollama模型部署完成提示词工程案例
- 什么是Prompt Engineering
- Prompt Engineering的原理以及实际应用的优化技巧
- 如何利用Prompt Engineering完成实际金融业务

智能体开发（Coze）

项目介绍

- 通过Coze平台快速搭建多种智能体应用（如问答助手、旅游规划、面试官），结合案例讲解与实践开发。

能力目标

- 学员能够掌握Coze平台的使用，快速从0到1构建多样化智能体工作流与应用程序。

解决方案

- 智能体平台选型解决方案
- Coze私有化部署解决防寒
- Coze智能体搭建解决方案

主讲知识点

- 案例：智能问答助手
- 案例：智能面试官
- 案例：旅游规划小精灵
- 案例：口语练习专家
- 案例：智能助教
- 案例讲2练3

基于Coze的技术面试助手



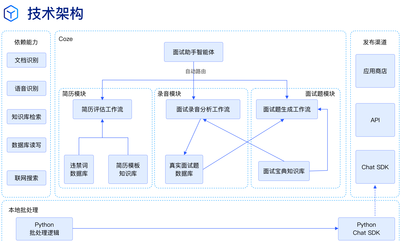
项目介绍

- 基于Coze工作流平台，结合LLM、ASR、TTS、RAG等技术，为黑马程序员AI学科学生构建面试全流程智能辅助系统，实现简历修改、面试录音分析、个性化面试题生成和实时语音模拟面试等功能。

能力目标

- 学员能够掌握Coze智能体开发范式，独立完成多场景智能体应用的构建与部署，实现工作流自动化与业务赋能。

技术架构



解决方案

- 实现基于插件完成PDF、DOCX等文档转文本到分析处理的全流程解决方案
- 实现基于ASR技术实现录音文件转文本到分析处理的全流程解决方案
- 实现基于知识库结合PDF实现精准内容生成的解决方案
- 实现在工作流中读写数据库和知识库的解决方案
- 实现父子模式多Agent架构自主规划执行解决方案

主讲知识点

实现如下功能：

- 简历修改：基于OCR插件、prompt、数据库查询，实现简历中各类常见问题的召回和修改建议。 以及进阶功能：违禁词过滤、业务背景重复率统计等。辅助学生编写更好的简历
- 面试录音分析：基于多模态大模型实现ASR，基于prompt实现面试官、应试者角色划分，最终实现文字提取、摘要以及建议，提面试高录音分析的效率
- 面试题生成：基于黑马面试宝典使用RAG技术结合学生的简历，结合简历上的技能点、业务背景、毕业时间、专业等信息，生成个性化的面试题题库
- 模拟面试：基于简历和面试题生成流水线等功能，基于那老师音色克隆面试官音色，结合ASR模型、TTS模型等技术，实现实时语音面试

智能体开发（Dify）

项目介绍

- 基于Docker部署Dify平台，结合Ollama私有化模型与RagFlow构建企业级评估智能体，实现知识库管理、可视化聊天界面及Agent系统开发。

能力目标

- 学员能够掌握Dify平台的集成开发与私有化部署，完成RAG知识库构建和智能评估Agent的系统搭建。

解决方案

- 项目基于Ollama私有化部署DeepSeek R1：8b模型
- 基于Docker结合Dify大模型应用开发平台构建可视化聊天界面

主讲知识点

- 大模型私有化部署：Ollama、DeepSeek/QWen
- 聊天机器人搭建：基于Dify搭建可视化聊天机器人
- RAG构建：基于Dify搭建本地知识库
- Agent智能体构建：基于Dify搭建Agent智能体

大模型智能体开发

大模型核心开发技术

课时：17天

课程亮点

- 熟悉大模型开发必备的机器学习核心基础和深度学习核心技术，掌握达模型核心Transformer架构与迁移学习，能够运用HuggingFace完成模型下载与加载使用。

能力目标

- 学员能够掌握机器学习和深度学习核心基础，完成 Bert及GPT核心Transformer架构分类的使用、能够完成分类模型基础搭建。

课程大纲

模块	技术点	详细知识点
深度学习与Pytorch框架	机器学习/深度学习	机器学习基础（术语、建模流程、核心框架、评估指标、分类回归聚类基础及案例）；深度学习基础（神经网络基础、Pytorch框架加强）
	Pytorch框架	Pytorch安装；Pytorch构建神经网络；Pytorch案例实战
Transformer基础	Transformer基础	词向量（Word Embedding）；Transformer（基本原理、实现流程）；BERT原理及使用；FastText原理及构建流程；BERT优化模型；迁移学习微调

蜂窝头条文本分类项目（NLP基础任务）



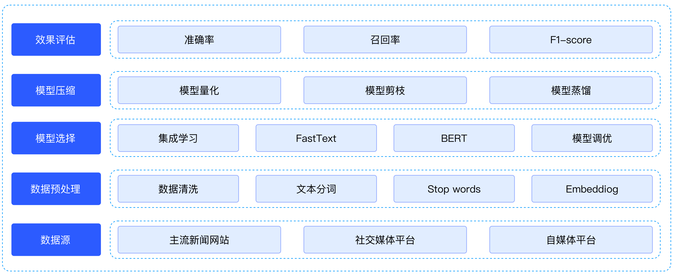
项目介绍

- 蜂窝头条投满分项目是结合今日头条真实场景下的海量数据， 快速搭建随机森林和FastText的基线模型，以验证商业化落地的可行性. 更多聚焦在深度学习的优化方法上，搭建基于BERT的初版微调模型， 应用量化,剪枝,预训练模型微调,知识蒸馏等多种手段,反复迭代,反复优化模型的离线效果,在线效果。

能力目标

- 基于大规模业务留存数据构建快速文本分类系统
- 快速搭建短文本精准分类模型
- 基于随机森林和FastText搭建快速基线模型, 验证业务通道的能力
- 基于BERT的迁移学习优化模型搭建的能力
- 实现神经网络量化的优化与测试
- 实现神经网络剪枝的优化与测试
- 实现神经网络知识蒸馏的优化与测试
- 更多主流预训练模型的优化与深度模型剖析
- BERT模型在生成式任务和工程优化上的深入扩展

技术架构



解决方案

- 海量文本快速分类基线模型解决方案
- 基于预训练模型优化的解决方案
- 模型量化优化的解决方案
- 模型剪枝优化的解决方案
- 模型知识蒸馏优化的解决方案
- 主流迁移学习模型微调优化的解决方案

主讲知识点

- 随机森林（集成学习）
- 基线模型（FastText）
- BERT优化
- 模型量化、剪枝、知识蒸馏
- 基于大模型文本分类

RAG应用开发

课时：10天

基于物流垂直领域的RAG智能问答项目

项目介绍

- 项目基于LangChain+Qwen/DeepSeek/ChatGLM-6B实现电商物流本地知识库问答机器人搭建，让模型根据本地信息进行准确回答，解决大模型的“幻觉”问题。实现精准问答，通过项目旨在掌握LangChain工具的基本使用方式，理解向量知识库以及实现知识库的技术原理。 快速构建检索增强生成（RAG）系统。

能力目标

- 掌握LangChain工具的基本使用方法，了解如何通过LangChain构建和管理语言模型应用
- 熟悉ChatGLM-6B模型的应用，了解如何将大语言模型与本地知识库结合，实现高效准确的问答功能
- 理解向量知识库的基本概念和技术原理，掌握如何构建和使用向量知识库来存储和检索知识信息
- 掌握知识库的构建方法，从数据采集，处理到存储，学习如何将电商物流相关信息整合到知识库中
- 理解RAG系统的基本原理和实现方法，学习如何结合检索和生成技术，提升问答系统的准确性和实用性
- 从零开始搭建一个问答机器人，掌握整个系统的设计、实现和部署过程

技术架构



解决方案

- LangChain工具使用介绍解决方案
- ChatGLM-6B模型集成到问答系统中的解决方案
- 向量知识库的构建和检索的解决方案
- 搭建RAG系统的解决方案

主讲知识点

- 项目介绍：理解什么是RAG系统
- 项目流程梳理（从本地知识库搭建，到知识检索，模型生成答案等流程介绍）
- 数据预处理：本地文档知识分割，向量，存储
- LangChain框架的详解讲解：6大组件应用原理和实现方法
- 基于本地大模型ChatGLM-6B封装到LangChain框架中
- 实现LangChain+ChatGLM-6B模型的知识库系统搭建

基于职业教育领域RAG智慧问答系统 AI讲



项目介绍

- 基于IT职业教育行业答疑大模型抽取RAG解决方案，通过项目学习完成企业级RAG系统完整流程搭建与测试及优化，从智能查询路由设计，数据处理与多源集成、模型微调到后端服务与前端开发完成全栈RAG系统构建。

能力目标

- 了解LangChain基本概念，明确LangChain主要组件的作用，了解LangChain常见的使用场景
- 掌握基于LangChain+ChatGLM-6B模型实现本地知识库的问答实现原理+过程
- RAG系统开发与优化：掌握从数据分片到答案生成的RAG全流程，熟练应用 HyDE、子查询等检索增强策略提升系统性能
- 大模型应用实践：能够集成 LLM（如 OllamaLLM）并设计高效 Prompt，解决知识问答中的企业定制化需求
- 智能查询路由设计：实现规则、相似度和 LLM 三层路由，精准分发查询并优化复杂意图识别效率
- 后端服务与前端开发：使用 FastAPI 开发高并发 API 并通过 Gradio 构建交互界面，满足企业级服务与用户体验要求
- 数据处理与多源集成：熟练处理结构化与非结构化数据，结合 MySQL 和向量搜索打造高效知识检索系统
- 企业级问题解决能力：通过日志调试和高并发设计，具备定制化开发与性能优化的实战技能，适配智能客服等场景

技术架构



解决方案

- BM25 + Redis 缓存解决方案
- Milvus 混合向量检索解决方案
- BERT 分类器解决方案
- LLM 驱动的策略选择解决方案
- LLM + RAG 提示模板解决方案
- Redis 缓存 + 模块化设计解决方案
- 统一日志系统（logging）解决方案
- ConfigParser + config.ini解决方案

主讲知识点

- 智能问答系统架构：FAQ 系统与 RAG 系统的区别与应用场景。
- 数据库技术：MySQL 表查询；Redis 键值存储与缓存机制；Milvus 向量数据库的架构与索引类型。
- 检索算法：BM25 算法原理；密集向量 & 稀疏向量混合检索；重排序的作用。
- query的意图识别+改写：BERT 分类器的训练与推理；LLM的调用与提示设计；查询分类与动态检索策略的实现逻辑。
- 企业级开发实践：模块化代码设计与代码复用；配置文件（config.ini）与环境变量管理；日志系统设计与错误处理。

基于人力资源场景的RAG的简历推荐系统 AI讲

项目介绍

- 项目基于向量数据库和 LLM 构建一个端到端、可水平扩展的检索增强生成（RAG）系统，支持对异构简历（PDF/DOCX/JPG/PNG）进行自动解析、结构化、语义索引与多轮对话式推荐。系统以向量数据库为核心存储，以LLM为推理中枢，以Agent框架为调度单元，面向企业 HR 及猎头平台提供秒级、可追溯、可解释的候选人推荐服务。

能力目标

- 学员能够掌握文档智能处理、向量化索引、RAG 系统开发及Agent框架应用，完成可扩展的简历推荐系统部署。

技术架构

解决方案

- 基于LangChain+OpenAI实现异构简历（PDF/DOCX/JPG/PNG）智能解析与结构化提取
- 使用Milvus+BGEM3混合嵌入+ElasticSearch实现高级向量索引与多路召回
- 构建支持参数过滤、查询重写与历史对话的异步RAG链生成JSON候选人推荐
- 基于SmartRecruitAgent框架实现意图识别、多轮追问与上下文候选人筛选的智能代理
- 集成Streamlit前端与Milvus/MongoDB/Elasticsearch多数据库持久化的DevOps配置
- 使用Ragas框架对RAG系统进行端到端Faithfulness/Answer Relevancy/Context Precision评估优化

主讲知识点

- 文档智能
- 向量化与索引
- 检索增强生成
- 智能代理
- 配置与 DevOps

智能体高级开发

课时：10天

智能体项目1（ReAct智能体）–InsightScan智扫通Agent项目



项目介绍

- 项目是一个面向消费者（toC）的智能客服系统，旨在为用户提供全周期的扫地机器人相关服务并根据用户使用习惯生成使用报告，为用户提供使用优化建议。该系统基于RAG技术及ReAct框架构建，涵盖产品咨询、使用报告生成与优化建议，通过一个统一的Agent界面，为用户提供高效、准确且个性化的支持，提升用户体验与满意度，结合三位一体评估体系和Flask/Streamlit部署实现商业化落地。

能力目标

- 学员能够掌握ReAct智能体开发流程，完成RAG工具调用、多维度评估系统搭建及生产级服务部署。具备构建可迭代优化的C端智能客服系统的能力。

技术架构



解决方案

- 基于ReAct框架实现的Agent
- RAG工具实现本地知识库构建
- Prompt Engineering实现用户使用报告的生成
- Flask的模型部署
- 基于Streamlit的前端服务构建

主讲知识点

- 数据来源：扫地机器人的产品手册及相关知识库（基础与技术类、产品功能类、智能交互类、维护与保养类、选购指南类、使用技巧类、配件与耗材类、安全与隐私类、特殊场景类等问题）
- 基于ReAct框架实现的Agent，包括推理（Reasoning）模块以及行动(Acting)模块。
- 使用RAG工具实现本地知识库构建，（文档读取模块、向量数据库模块、RAG工具调用模块）
- 使用大模型Deepseek v3结合Prompt Engineering实现用户使用报告的生成
- 构建三位一体评估体系，针对检索内容（Precision、Recall、mrr），生成内容（ROUGE-1，ROUGE-L、BERTScore、Faithfulness），总性能（平均延时、QPS）
- 构建日志打印模块，重点监控工具的运行情况。（控制台日志+生产环境日志）
- 基于Flask的模型部署（服务端+客户端），基于Streamlit的前端服务。

智能体项目2（多智能体）–基于A2A的SmartVoyage旅行智能助手 NEW



项目介绍

- SmartVoyage是一个智能旅行助手系统，使用A2A(Agent-to-Agent) 协议构建多代理协作框架，支持用户查询天气和票务信息。系统包括LLM路由服务器（意图识别）、天气代理服务器（查询天气数据库）、票务代理服务器（查询票务数据库）、MCP工具服务器（数据库接口）、数据库集脚本和Streamlit前端客户端。用户输入查询（如"北京天气"或"北京到上海火车票"），系统通过LLM路由到合适代理，代理生成SQL查询MCP 数据库，返回结果显示在界面。

能力目标

- 学员能够掌握A2A多代理框架开发、意图识别与数据库查询技能，完成交互式旅行助手系统的构建。

技术架构



解决方案

- 基于Python–a2a协议实现多代理A2A协作框架
- 使用LangChain+DeepSeek构建LLM路由服务器意图识别与动态路由
- 实现MCP工具服务器标准在MySQL查询接口
- 天气代理服务器LangChain SQL生成与MCP实时天气数据库查询集成
- 票务代理服务器多类型动态SQL生成与结果友好格式化
- 基于Streamlit开发A2A多代理实时交互前端客户端

主讲知识点

- LLM 路由服务器（意图识别）
- 天气代理服务器（查询天气数据库）
- 票务代理服务器（查询票务数据库）
- MCP 工具服务器（数据库接口）
- 数据库集脚本
- Streamlit 前端客户端

智能体项目2（多智能体）–基于多场景的Agent智能工单项目 NEW

项目介绍

- 大型ToC企业中的客服团队往往是人力外包，对公司业务细节的了解程度不够，需要和产研团队多次沟通才能完成一次工单的处理，效率低下。同时，随着AI的发展，工单的处理也可以基于大模型+RAG+function call能力进行提效，部分工单自动处理，从而节省部分客服人力资源。
本系统结合大模型能力，融合多种AI技术（RAG+多Agent+MCP）等，结合Kafka消息队列、PostgreSQL向量检索和Docker容器化部署，完成大型企业工单的判定、处理、建议与知识库实时迭代等全流程流转闭环，解决传统客服流程低效问题。

能力目标

- 学员能够掌握企业级智能工单系统架构设计，实现基于规则过滤、查询改写、意图识别的全流程自动化处理，具备复杂业务场景下多智能体系统的开发与运维能力。

技术架构

解决方案

- 使用无侵入的方式实时处理业务系统数据的解决方案
- 实现企业私有化数据脱敏的解决方案
- 实现基于多层模型实现复杂分类的解决方案
- 实现基于RAG+MCP调用实现融合知识库+API的上下文工程的解决方案
- 实现动态更新知识库的解决方案
- 实现docker镜像构建和服务器部署的企业部署解决方案

主讲知识点

- 项目冷启动阶段，基于大模型+NLP算法，完成工单数据的清洗和工单、业务知识库的搭建（PG），工单会进行脱敏
- 消费工单的Kafka消息队列数据，并基于规则过滤出来需要处理的工单；
- 实现query改写，提高检索内容的准确性，对PG进行检索时采用上下文+向量混合检索的方式，结合重排序模型实现查询内容的准确性
- 实现意图识别和槽位填充，基于用户的query基于MCP协议执行function call，在上下文中补充用户的实时数据作为上下文信息
- 实现知识库实时迭代，实现知识库数据实时更新，保证内容是最新的
- Docker镜像的构建和生产环境docker–compose模式部署

大模型定制开发

大模型核心运行机制

课时：5天

课程亮点

- 深入剖析Transformer架构核心组件及其实战应用，结合PyTorch和HuggingFace实现翻译任务。
- 聚焦预训练模型与微调流程，结合HuggingFace工具实现中文分类、填空等任务。
- 深入讲解GPT、DeepSeek、QWen的架构设计与预训练任务，剖析模型运行机制，为后续微调提供理论基础。

能力目标

- 能够理解Transformer的注意力机制与架构设计，并掌握基于Transformer的翻译任务开发技能。
- 能够使用HuggingFace库对预训练模型进行全量微调，完成特定NLP任务。
- 能够理解主流大模型的架构特性与预训练原理，掌握为微调任务选择合适模型的能力。

课程大纲

模块	技术点	详细知识点
大模型Transformer架构	大模型Transformer架构	词向量（Word Embedding）；大模型Transformer架构的注意力机制；大模型Transformer架构（encoder、decoder、encoder+decoder）；大模型Transformer翻译任务实战
大模型迁移学习	大模型迁移学习	迁移学习的预训练模型和微调阶段；NLP中的常用预训练模型（BERT、GPT-1、GPT-2）；Hugging Face预训练模型仓库；Huggingface Transformers库使用（提供了NLP领域预训练语言模型结构模型和调用框架）；基于微调方式实现中文分类、中文填空、句子关系等任务
大模型主流模型运行机制	大模型主流模型运行机制	GPT/DeepSeek/QWen基础；GPT/DeepSeek/QWen架构变化；GPT/DeepSeek/QWen的预训练任务；基于DeepSeek/QWen预训练+微调任务实战

大模型微调开发

课时：10天

【LoRA微调】微博文本信息抽取项目



项目介绍

- 项目基于Qwen/DeepSeek，通过LoRA和P-Tuning实现微博文本信息抽取+文本分类的多任务，通过一个大模型同时解决多种任务开发和应用。

能力目标

- 了解和掌握大语言模型的基本原理和架构，特别是ChatGLM-6B模型的结构和工作机制
- 掌握大模型LoRA微调技术，通过微调预训练的大模型来适应特定任务的需求
- 掌握大模型P-Tuning微调技术，对大模型进行高效的参数调整，增强其在特定任务上的表现
- 理解和应用多任务学习的概念，通过一个模型同时解决文本信息抽取和文本分类两种任务，提高模型的综合能力和应用效率
- 掌握文本信息抽取技术，从非结构化的文本数据中提取有价值的信息，如实体、关系、事件等
- 学习文本分类的基本原理和方法，掌握如何将文本数据按照预定义的类别进行归类通过Flask框架，学习如何开发和部署API接口，使模型能够通过网络服务被访问和使用

技术架构



解决方案

- 联合任务数据预处理适配模型训练的解决方案
- 实现ChatGLM-6B+LoRA训练的解决方案
- 实现ChatGLM-6B+P-Tuning训练的解决方案
- 基于Flask框架实现模型API接口开发的解决方案

主讲知识点

- 理解信息抽取任务以及文本分类的业务意义及应用场景
- 数据预处理：修改数据格式适配大模型训练、数据张量的转换等
- Qwen/DeepSeek模型解析，LoRA方法详解，P-Tuning方法解析
- 基于Qwen/DeepSeek+LoRA方法实现模型的训练和评估
- 基于Qwen/DeepSeek+P-Tuning方法实现模型的训练和评估
- 基于Flask框架开发API接口，实现模型线上应用

【QLoRA微调】QWen微调文本摘要项目



项目介绍

- 项目以QWen模型为核心，借助DeepSpeed框架实现训练过程的加速优化，同时采用了GPTQ和QLoRA技术对模型进行量化处理，旨在进一步提升模型的推理速度。最终，通过Vllm平台完成了模型的部署，实现了对文本中关键信息的自动化抽取，完成信息抽取的任务。

能力目标

- 学员能够掌握QLoRA量化微调与并行计算技术，完成文本摘要模型的高效训练与部署。

技术架构



解决方案

- 大模型并行计算解决方案
- 大模型量化解决方案
- 大模型部署解决方案
- 大模型推理优化解决方案

主讲知识点

- 数据集处理、模型构建、模型训练、模型预测
- 大模型并行计算：deepspeed,数据并行、流水线并行、模型并行
- 大模型量化:训练量化方法QLora，训练后量化方法GPTQ
- 模型部署和推理优化框架：vLLM和oLLAMA

基于中医药知识图谱项目

项目介绍

- “草本通”项目致力于解决中医药知识难以理解、碎片化严重、检索效率低等问题，通过爬虫、DeepSeek+LangChain实体抽取、Neo4j图谱构建与LangGraph多智能体协同，打造一个可理解、可对话、可传播、可拓展的智能知识服务平台。系统融合多种AI技术，支持从数据采集到语义问答、图谱构建，再到内容生成与平台发布的完整AI闭环。

能力目标

- 学员能够掌握知识图谱构建、多智能体流程调度及生成式应用开发，具备覆盖领域知识智能化平台的搭建能力。

技术架构

解决方案

- 多源中医药数据爬取与联合任务数据预处理适配知识图谱构建的解决方案
- 基于Neo4j+FAISS的中医药知识图谱检索增强（RAG）解决方案
- 基于LangGraph的中医药智能问答与多意图工作流编排解决方案
- 基于 FastAPI 实现LangGraph智能体流式API接口开发的解决方案
- 基于LamaFactory微调大模型进行实体关系生成的解决方案

主讲知识点

- 利用爬虫自动采集中药、方剂、功效、症状、疾病等原始文本
- 使用大语言模型（DeepSeek）+ LangChain 进行实体与关系抽取
- 构建Neo4j图数据库与Faiss向量检索引擎，实现结构化查询与语义匹配
- 基于LangGraph搭建多智能体协同系统，管理复杂问答流程
- 提供基于Streamlit的网页端交互式问答界面
- 自动生成小红书风格图文内容，并实现一键发布，实现从“知识获取”到“内容传播”的闭环

大模型算法进阶

CV图像分析

课时：6天

课程亮点

- 深入讲解CNN、ResNet原理，YoloV系列目标检测算法及Unet、MaskRCNN的图像分类与分割技术，结合理论与应用场景。

能力目标

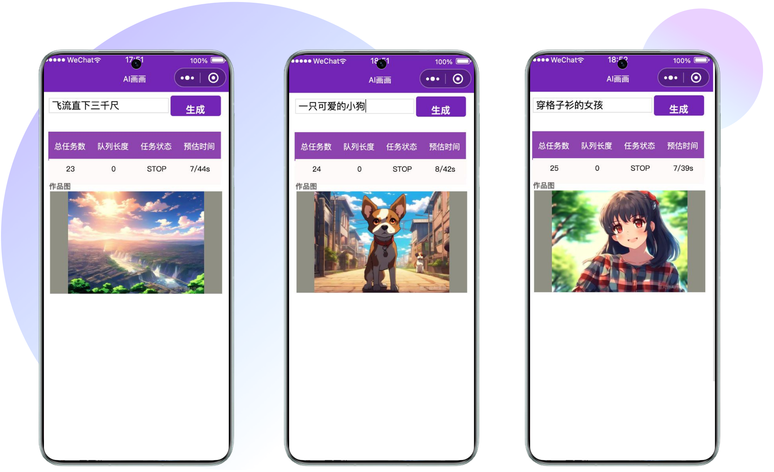
- 学员能够掌握CNN、ResNet、Yolo及分割算法的核心原理，具备开发图像分类与目标检测应用的能力。

课程大纲

模块	技术点	详细知识点
计算机视觉背景	计算机视觉背景、任务、发展历史介绍	计算机视觉定义；计算机视觉的任务；计算机视觉的应用领域；计算机视觉的发展历史
图像分析特性	图像特性分析与图像处理实践	图像的表示方法；图像的IO操作；图像的颜色空间；图像的加法；图像混合；图像的几何变换；图像噪声；图像平滑方法
图像分类	图像分类任务详解与图像增强技术实践	图像分类任务详解；图像分类的数据集；图像分类的评估方法；常用的图像增强方法；tf.image进行图像增强；imagedatagenrator进行图像增强；模型微调；数据集获取；【案例】图像几何颜色增强实践
	围像分类的经典网络结构与鲜花分类案例实践	图像分类的CNN网络回顾；AlexNet网络实践；VGG网络架构；GoogLeNet详解与实践；Inception系列网络；ResNet网络结构与实践；残差块和瓶颈块；【案例】鲜花分类案例
图像分割	图像的语义分割详解及Unet实现VOC语义分割案例	图像分割定义；图像分割的类型；图像分割的开源数据集；图像分割的评估指标；unet网络结构；语义分割VOC数据集获取；数据集生成器；模型构建；编码器实践；解码器实践；模型训练；模型预测；【案例】基于Unet的VOC数据的语义分割案例
	图像的实例分割详解及MaskRCNN气球实例分割案例	图像实例分割；MaskRCNN的网络构成；MaskRCNN的流程；ROIAlign原理与实践；气球分割数据集的获取；模型训练；损失函数的实践；模型预测；【案例】MaskRCNN气球实例分割实践

多模态大模型应用开发

课时：6天



项目介绍

基于Stable Diffusion的图像生成项目是一种基于深度学习的图像生成方法，旨在通过AIGC技术与Stable Diffusion算法，结合LoRA和Dreambooth微调，开发图像生成小程序，覆盖文生图AIGC场景，生成高质量、逼真的图像。该项目利用稳定扩散过程，通过逐渐模糊和清晰化图像来实现图像生成的过程。这种方法在图像生成领域具有广泛的应用，包括艺术创作、虚拟场景生成、数据增强等。

能力目标

学员能够理解AIGC与Diffusion模型原理，掌握Stable Diffusion的模型构建与微调，完成图像生成小程序的开发。

技术架构

图像生成	文生图	图生图	图像修复		
模型训练	LoRA	dreambooth	Hypernetwork	Textual Inversion	
模型构成	CLIP	Diftusiong	Latent Diffusion	VAE	Unet
输入数据	文本数据	图像数据	姿态数据		

解决方案

- 图像生成的常见解决方案
- 文图匹配的解决方案
- 扩散模型噪声去除的解决方案
- 潜在空间扩散模型的解决方案
- 扩散模型训练的解决方案
- 小程序搭建的解决方案

主讲知识点

- AIGC的详解：AIGC简介，类型，应用场景，产品形态
- 图像生成算法：GAN，VAE，Diffusion，DALLe，imagen
- StableDiffusion的详解：Diffusion，latent diffusion；satble diffusion
- stablediffusion实践：模型构建，模型训练，lora，dreambooth，图像生成效果
- 图像生成小程序搭建：基于stablediffusion构建图像生成的小程序

培养直面企业需求的
全栈大模型研发工程师，
从应用开发到核心算法，
赋能业务智能升级



黑马程序员
www.itheima.com

传智播客旗下高端IT教育品牌

北京 | 上海 | 广州 | 深圳 | 武汉 | 郑州 | 西安 | 长沙 | 济南 | 杭州 | 南京 | 成都